

Proyecto 2 – Maternidad Adolescente en Guatemala (2009–2023)

Grupo 6

2026-05-15

Contents

1. Librerías	2
2. Variable Respuesta	2
3. Carga de datos	2
4. Limpieza y construcción de variables	3
5. Selección de variables predictoras y dataset final	3
6. Análisis de desbalance	4
7. División Train / Test (70 / 30, estratificada)	5
8. Exportar datos para el grupo	6
9. Función auxiliar de métricas	7
10. Regresión Logística	8
Modelo 1 — Sin balancear, threshold 0.5	8
Modelo 2 — Con ROSE balanceado, threshold 0.5	10
Modelo 3 — Con ROSE balanceado, threshold 0.3	12
11. Comparación de modelos	12
12. Curvas ROC comparativas	13
13. Modelo final seleccionado	15
14. Interpretación de coeficientes	16

1. Librerías

```
library(haven)
library(dplyr)
library(tidyr)
library(ggplot2)
library(caret)
library(ROSE)
library(pROC)
```

Instalar paquetes nuevos si es necesario: `install.packages(c("caret", "ROSE", "pROC", "tidyr"))`

2. Variable Respuesta

La variable respuesta es **adolescente** (binaria):

- 1 = nacimiento en madre menor de 18 años
- 0 = nacimiento en madre de 18 años o más

Es una variable **cualitativa / categórica binaria**, por lo que el problema es de **clasificación**. Se eligió esta variable porque fue el eje central del análisis exploratorio del Proyecto 1, donde se identificaron patrones territoriales, educativos y étnicos asociados al fenómeno. Predecir si un nacimiento corresponde a una madre adolescente permite identificar los factores más relevantes y diseñar intervenciones focalizadas.

3. Carga de datos

```
archivos <- list.files("Datos", pattern = "\\..sav$", full.names = TRUE)
df_test <- read_sav(archivos[1])

lista_datos <- lapply(archivos, function(x) {
  df <- read_sav(x)
  df <- zap_labels(df)
  df[] <- lapply(df, as.character)
  df
})

datos_unidos <- bind_rows(lista_datos)
cat("Registros totales:", nrow(datos_unidos), "\n")
```

```
## Registros totales: 5195195
```

4. Limpieza y construcción de variables

```
# --- Año ---
datos_unidos$Añoreg <- ifelse(nchar(datos_unidos$Añoreg) == 1,
                             paste0("200", datos_unidos$Añoreg),
                             ifelse(nchar(datos_unidos$Añoreg) == 2,
                                     paste0("20", datos_unidos$Añoreg),
                                     datos_unidos$Añoreg))
datos_unidos$Añoreg <- as.numeric(datos_unidos$Añoreg)

# --- Edad materna ---
datos_unidos$Edadm <- as.numeric(datos_unidos$Edadm)
datos_unidos$Edadm[datos_unidos$Edadm == 999] <- NA

# --- Variable respuesta ---
datos_unidos$adolescente <- ifelse(datos_unidos$Edadm < 18, 1, 0)

# --- Factores con etiquetas oficiales ---
labels_depto <- attr(df_test$Deprem, "labels")
labels_educ <- attr(df_test$Escolam, "labels")
labels_etnia <- attr(df_test$Pueblopm, "labels")
labels_sitio <- attr(df_test$Sitioocu, "labels")

datos_unidos$Deprem <- factor(datos_unidos$Deprem, levels = labels_depto, labels = names(labels_depto))
datos_unidos$Escolam <- factor(datos_unidos$Escolam, levels = labels_educ, labels = names(labels_educ))
datos_unidos$Pueblopm <- factor(datos_unidos$Pueblopm, levels = labels_etnia, labels = names(labels_etnia))
datos_unidos$Sitioocu <- factor(datos_unidos$Sitioocu, levels = labels_sitio, labels = names(labels_sitio))
```

5. Selección de variables predictoras y dataset final

Se seleccionan las variables con mayor poder explicativo identificadas en el EDA del Proyecto 1. Se excluyen registros con NA y categorías “Ignorado”.

```
df_modelo <- datos_unidos %>%
  select(adolescente, Añoreg, Escolam, Pueblopm, Sitioocu, Deprem) %>%
  filter(
    !is.na(adolescente),
    !is.na(Escolam),
    !is.na(Pueblopm),
    !is.na(Sitioocu),
    !is.na(Deprem),
    Escolam != "Ignorado",
    Pueblopm != "Ignorado",
    Sitioocu != "Ignorado",
    Deprem != "Ignorado"
  ) %>%
  mutate(
    adolescente = factor(adolescente, levels = c(0, 1), labels = c("No", "Si")),
    Añoreg      = as.numeric(Añoreg)
```

```
)

df_modelo <- droplevels(df_modelo)

cat("Registros después de limpieza:", nrow(df_modelo), "\n")
```

```
## Registros después de limpieza: 293943
```

```
glimpse(df_modelo)
```

```
## Rows: 293,943
## Columns: 6
## $ adolescente <fct> No, No, No, No, Si, No, No, No, No, No, No, No, No, No, No~
## $ Añoereg <dbl> 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022~
## $ Escolam <fct> Diversificado, Diversificado, Primaria, Primaria, Primaria~
## $ Pueblopm <fct> Mestizo / Ladino, Mestizo / Ladino, Mestizo / Ladino, Mest~
## $ Sitioocu <fct> Centro de salud, Centro de salud, Centro de salud, Centro ~
## $ Deprem <fct> Chimaltenango, Guatemala, Santa Rosa, Escuintla, Solola, Q~
```

Las variables seleccionadas son:

Variable	Descripción	Tipo
Añoereg	Año de registro del nacimiento	Númerica
Escolam	Nivel educativo de la madre	Categórica
Pueblopm	Grupo étnico de la madre	Categórica
Sitioocu	Lugar de ocurrencia del nacimiento	Categórica
Deprem	Departamento de residencia	Categórica

6. Análisis de desbalance

```
tabla_clase <- table(df_modelo$adolescente)
prop_clase <- prop.table(tabla_clase)


print(tabla_clase)
```

```
##
##      No      Si
## 288210  5733
```

```
print(round(prop_clase * 100, 2))
```

```
##
##      No      Si
## 98.05  1.95
```

```
ggplot(as.data.frame(prop_clase), aes(x = Var1, y = Freq, fill = Var1)) +
  geom_bar(stat = "identity") +
  scale_fill_manual(values = c("#4292c6", "#d62728")) +
  labs(title = "Distribución de la variable respuesta",
       x = "Maternidad adolescente", y = "Proporción") +
  theme_minimal() +
  theme(legend.position = "none")
```



El dataset presenta un desbalance severo: aproximadamente el 98% de los registros corresponden a madres no adolescentes y solo el 2% a madres menores de 18 años. Esto ocurre porque al filtrar las categorías “Ignorado” y NAs, muchos registros de madres adolescentes fueron eliminados junto con los demás.

Este desbalance tiene implicaciones directas en el modelado: un clasificador que prediga siempre “No” tendría ~98% de accuracy sin aprender nada útil. Por esta razón se utilizará oversampling (ROSE) para balancear el conjunto de entrenamiento, y se reportarán F1-score y AUC-ROC como métricas principales en lugar de accuracy.

7. División Train / Test (70 / 30, estratificada)

Se usa `createDataPartition` de `caret` para garantizar que ambas particiones conserven la misma proporción de la clase minoritaria.

```
set.seed(123)

idx_train <- createDataPartition(df_modelo$adolescente, p = 0.70, list = FALSE)

train_data <- df_modelo[ idx_train, ]
test_data  <- df_modelo[-idx_train, ]

cat("Registros en train:", nrow(train_data), "\n")
```

```
## Registros en train: 205761
```

```
cat("Registros en test: ", nrow(test_data), "\n")
```

```
## Registros en test: 88182
```

```
cat("\nProporción en TRAIN:\n")
```

```
##
## Proporción en TRAIN:
```

```
print(round(prop.table(table(train_data$adolescente)) * 100, 2))
```

```
##
##      No      Si
## 98.05  1.95
```

```
cat("\nProporción en TEST:\n")
```

```
##
## Proporción en TEST:
```

```
print(round(prop.table(table(test_data$adolescente)) * 100, 2))
```

```
##
##      No      Si
## 98.05  1.95
```

Se utilizó una división 70/30 estratificada. La estratificación garantiza que el desbalance original se preserve en ambas particiones, evitando que por azar una de ellas tenga una proporción distinta de la clase minoritaria. El conjunto de prueba no será modificado en ningún momento durante el entrenamiento.

8. Exportar datos para el grupo

```
saveRDS(train_data, "train_data.rds")
saveRDS(test_data, "test_data.rds")
cat("Archivos guardados: train_data.rds y test_data.rds\n")
```

```
## Archivos guardados: train_data.rds y test_data.rds
```

9. Función auxiliar de métricas

Para mantener consistencia entre los 3 modelos, se define una función que calcula accuracy, precisión, recall, F1-score y AUC-ROC sobre el conjunto de prueba.

```
evaluar_modelo <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {
  probs <- predict(modelo, newdata = datos_test, type = "response")
  preds <- factor(ifelse(probs >= threshold, "Si", "No"),
                  levels = c("No", "Si"))

  cm      <- confusionMatrix(preds, datos_test$adolescente, positive = "Si")
  roc_obj <- roc(as.numeric(datos_test$adolescente == "Si"), probs, quiet = TRUE)
  auc_val <- auc(roc_obj)

  cat("\n===== \n")
  cat(" Modelo:", nombre_modelo, "\n")
  cat(" Threshold:", threshold, "\n")
  cat("===== \n")
  print(cm$table)
  cat("\nAccuracy :", round(cm$overall["Accuracy"], 4), "\n")
  cat("Precision:", round(cm$byClass["Precision"], 4), "\n")
  cat("Recall    :", round(cm$byClass["Recall"], 4), "\n")
  cat("F1-score  :", round(cm$byClass["F1"], 4), "\n")
  cat("AUC-ROC   :", round(auc_val, 4), "\n")

  list(
    nombre = nombre_modelo,
    threshold = threshold,
    accuracy = cm$overall["Accuracy"],
    precision = cm$byClass["Precision"],
    recall = cm$byClass["Recall"],
    f1 = cm$byClass["F1"],
    auc = as.numeric(auc_val),
    roc = roc_obj,
    cm = cm
  )
}
```

10. Regresión Logística

La regresión logística es un algoritmo de clasificación binaria que modela la probabilidad de pertenecer a la clase positiva mediante una función sigmoide. Es interpretable, eficiente computacionalmente y sirve como línea base para comparar contra algoritmos más complejos. Maneja variables categóricas directamente como factores en R sin necesidad de codificación manual.

Modelo 1 — Sin balancear, threshold 0.5

Este modelo sirve como línea base. Se espera alta accuracy pero bajo recall en la clase “Si” debido al desbalance severo.

```
set.seed(123)

m1 <- glm(adolescente ~ .,
          data = train_data,
          family = binomial(link = "logit"))

summary(m1)
```

```
##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -852.96734    77.55997  -10.998  < 2e-16 ***
## Añoreg           0.41991     0.03835   10.948  < 2e-16 ***
## EscolamPrimaria  0.24131     0.04208    5.735 9.78e-09 ***
## EscolamBásica   -0.00522     0.05535   -0.094 0.924859
## EscolamDiversificado -1.64355     0.09908  -16.589  < 2e-16 ***
## EscolamUniversitario -14.21779    96.43438   -0.147 0.882789
## EscolamPost Grado -14.07765   483.94503   -0.029 0.976793
## PueblopGarifuna  -14.75348   899.96057   -0.016 0.986920
## PueblopXinka     -0.43678     0.39678   -1.101 0.270977
## PueblopMestizo / Ladino -0.24523     0.04554   -5.385 7.24e-08 ***
## PueblopOtro      -1.23155     0.19279   -6.388 1.68e-10 ***
## SitioocuHospital privado -0.25945     0.05816   -4.461 8.14e-06 ***
## SitioocuCentro de salud -0.15328     0.05838   -2.626 0.008647 **
## SitioocuSeguro social  -3.26730     0.35545   -9.192  < 2e-16 ***
## SitioocuVía Pública  -0.74742     0.71324   -1.048 0.294674
## SitioocuDomicilio    -0.08913     0.04028   -2.213 0.026914 *
## SitioocuOtro         2.02368     1.16931    1.731 0.083512 .
## DepremEl Progreso     1.33060     0.11994   11.094  < 2e-16 ***
## DepremSacatepequez   -0.46309     0.20353   -2.275 0.022888 *
## DepremChimaltenango  -0.66634     0.13363   -4.986 6.15e-07 ***
## DepremEscuintla       0.59208     0.10151    5.833 5.45e-09 ***
## DepremSanta Rosa     -1.86029     0.33984   -5.474 4.40e-08 ***
## DepremSolola          0.03317     0.11786    0.281 0.778358
## DepremTotonicapan    -0.70424     0.13595   -5.180 2.22e-07 ***
## DepremQuetzaltenango  0.19761     0.09738    2.029 0.042440 *
```



```
## DepremSuchitepequez      0.64916    0.09778    6.639 3.16e-11 ***
## DepremRetalhuleu         0.84637    0.11073    7.643 2.11e-14 ***
## DepremSan Marcos         0.42573    0.08175    5.208 1.91e-07 ***
## DepremHuehuetenango      0.31023    0.07891    3.932 8.44e-05 ***
## DepremQuiche             0.24765    0.08280    2.991 0.002780 **
## DepremBaja Verapaz       -0.02470    0.13390   -0.184 0.853674
## DepremAlta Verapaz        0.27180    0.08155    3.333 0.000859 ***
## DepremPeten              0.32918    0.09457    3.481 0.000500 ***
## DepremIzabal             1.09977    0.08930   12.315 < 2e-16 ***
## DepremZacapa             0.78768    0.12137    6.490 8.58e-11 ***
## DepremChiquimula         -0.38458    0.13468   -2.855 0.004298 **
## DepremJalapa             -0.60053    0.17086   -3.515 0.000440 ***
## DepremJutiapa            -0.47058    0.16000   -2.941 0.003270 **
## DepremExtranjero         -0.02441    1.01219   -0.024 0.980758
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 39555  on 205760  degrees of freedom
## Residual deviance: 36898  on 205722  degrees of freedom
## AIC: 36976
##
## Number of Fisher Scoring iterations: 17
```

```
res1 <- evaluar_modelo(m1, test_data,
                       nombre_modelo = "M1 - Sin balancear, threshold 0.5")
```

```
##
## =====
## Modelo: M1 - Sin balancear, threshold 0.5
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0     0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.7212
```

Como se esperaba, el modelo sin balancear tiene accuracy alta (~98%) pero un recall muy bajo para la clase “Si”. El modelo aprende a predecir casi siempre “No” porque esa clase domina el conjunto de entrenamiento. Esto confirma que accuracy no es una métrica adecuada para este problema y que es necesario corregir el desbalance.

Modelo 2 — Con ROSE balanceado, threshold 0.5

Se aplica oversampling con ROSE sobre el conjunto de entrenamiento para balancear las clases. El conjunto de prueba no se modifica, ya que debe representar la distribución real del fenómeno.

```
set.seed(123)

train_balanced <- ROSE(adolescente ~ ., data = train_data, seed = 123)$data

cat("Distribución en train balanceado:\n")
```

```
## Distribución en train balanceado:
```

```
print(table(train_balanced$adolescente))
```

```
##
##      No      Si
## 103155 102606
```

```
m2 <- glm(adolescente ~ .,
          data = train_balanced,
          family = binomial(link = "logit"))

summary(m2)
```

```
##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_balanced)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -979.86800    24.78122  -39.541 < 2e-16 ***
## Añoreg           0.48459     0.01225   39.543 < 2e-16 ***
## EscolamPrimaria  0.22085     0.01269   17.401 < 2e-16 ***
## EscolamBásica   -0.02664     0.01619   -1.646 0.099849 .
## EscolamDiversificado -1.66508     0.02313  -71.977 < 2e-16 ***
## EscolamUniversitario -15.06947    29.04741   -0.519 0.603908
## EscolamPost Grado -14.97642   146.76880   -0.102 0.918724
## PueblopmGarifuna -15.69870   259.97752   -0.060 0.951849
## PueblopmXinka    -0.49192     0.09836   -5.001 5.70e-07 ***
## PueblopmMestizo / Ladino -0.18059     0.01432  -12.615 < 2e-16 ***
## PueblopmOtro     -1.19260     0.04570  -26.094 < 2e-16 ***
## SitioocuHospital privado -0.24220     0.01639  -14.779 < 2e-16 ***
## SitioocuCentro de salud -0.07754     0.01736   -4.466 7.97e-06 ***
## SitioocuSeguro social  -3.21317     0.07133  -45.046 < 2e-16 ***
## SitioocuVía Pública  -0.70601     0.20033   -3.524 0.000425 ***
## SitioocuDomicilio   -0.02435     0.01244   -1.957 0.050300 .
## SitioocuOtro        3.52567     1.01441    3.476 0.000510 ***
## DepremEl Progreso    1.28671     0.04222   30.476 < 2e-16 ***
## DepremSacatepequez  -0.51457     0.05154   -9.984 < 2e-16 ***
## DepremChimaltenango -0.65554     0.03416  -19.190 < 2e-16 ***
```

```

## DepremEscuintla      0.49897    0.02967   16.815 < 2e-16 ***
## DepremSanta Rosa    -1.82015    0.06959  -26.157 < 2e-16 ***
## DepremSolola         0.07457    0.03379    2.207 0.027337 *
## DepremTotonicapan   -0.77167    0.03544  -21.775 < 2e-16 ***
## DepremQuetzaltenango 0.25114    0.02789    9.003 < 2e-16 ***
## DepremSuchitepequez 0.60986    0.02942   20.733 < 2e-16 ***
## DepremRetalhuleu     0.79608    0.03486   22.833 < 2e-16 ***
## DepremSan Marcos     0.43591    0.02357   18.497 < 2e-16 ***
## DepremHuehuetenango 0.28228    0.02334   12.094 < 2e-16 ***
## DepremQuiche         0.24333    0.02445    9.953 < 2e-16 ***
## DepremBaja Verapaz   -0.03414    0.03788   -0.901 0.367358
## DepremAlta Verapaz   0.20874    0.02412    8.653 < 2e-16 ***
## DepremPeten          0.24218    0.02750    8.806 < 2e-16 ***
## DepremIzabal         0.97384    0.02952   32.991 < 2e-16 ***
## DepremZacapa         0.68842    0.03785   18.190 < 2e-16 ***
## DepremChiquimula     -0.41194    0.03464  -11.891 < 2e-16 ***
## DepremJalapa         -0.66281    0.04198  -15.788 < 2e-16 ***
## DepremJutiapa        -0.44453    0.03914  -11.356 < 2e-16 ***
## DepremExtranjero      0.51389    0.23115    2.223 0.026203 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 285244  on 205760  degrees of freedom
## Residual deviance: 247111  on 205722  degrees of freedom
## AIC: 247189
##
## Number of Fisher Scoring iterations: 14

```

```

res2 <- evaluar_modelo(m2, test_data,
                       nombre_modelo = "M2 - ROSE balanceado, threshold 0.5")

```

```

##
## =====
## Modelo: M2 - ROSE balanceado, threshold 0.5
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 41772  315
##           Si 44691 1404
##
## Accuracy : 0.4896
## Precision: 0.0305
## Recall   : 0.8168
## F1-score : 0.0587
## AUC-ROC  : 0.7177

```

Al balancear las clases con ROSE, el recall mejora considerablemente. La accuracy baja porque el modelo ya no predice siempre “No”, lo cual es el comportamiento correcto. El F1-score y AUC-ROC son mejores indicadores de rendimiento en este contexto y deben ser las métricas de referencia para comparar modelos.

Modelo 3 — Con ROSE balanceado, threshold 0.3

Se mantiene el mismo modelo entrenado con ROSE pero se ajusta el threshold de decisión de 0.5 a 0.3. Al bajar el threshold, el modelo clasifica como “Si” con menor confianza requerida, lo que aumenta el recall a costa de algo de precisión. En contextos de salud pública suele preferirse detectar más casos verdaderos (mayor recall) aunque se generen más falsos positivos.

```
res3 <- evaluar_modelo(m2, test_data,
                      nombre_modelo = "M3 - ROSE balanceado, threshold 0.3",
                      threshold      = 0.3)
```

```
##
## =====
## Modelo: M3 - ROSE balanceado, threshold 0.3
## Threshold: 0.3
## =====
##           Reference
## Prediction    No    Si
##           No 25747    77
##           Si 60716 1642
##
## Accuracy : 0.3106
## Precision: 0.0263
## Recall   : 0.9552
## F1-score : 0.0513
## AUC-ROC  : 0.7177
```

Con threshold 0.3 el recall aumenta respecto al Modelo 2, detectando más casos de maternidad adolescente. Sin embargo, la precisión disminuye porque también aumentan los falsos positivos. Este trade-off es relevante para el problema: dependiendo del uso de los resultados, puede ser preferible detectar más casos a riesgo de generar algunas alertas innecesarias.

11. Comparación de modelos


```
resumen <- data.frame(
  Modelo    = c(res1$nombre, res2$nombre, res3$nombre),
  Accuracy  = round(c(res1$accuracy, res2$accuracy, res3$accuracy), 4),
  Precision = round(c(res1$precision, res2$precision, res3$precision), 4),
  Recall    = round(c(res1$recall, res2$recall, res3$recall), 4),
  F1        = round(c(res1$f1, res2$f1, res3$f1), 4),
  AUC_ROC   = round(c(res1$auc, res2$auc, res3$auc), 4)
)

print(resumen)
```

##		Modelo	Accuracy	Precision	Recall	F1	AUC_ROC
## 1	M1 - Sin balancear, threshold 0.5		0.9805	NA	0.0000	NA	0.7212
## 2	M2 - ROSE balanceado, threshold 0.5		0.4896	0.0305	0.8168	0.0587	0.7177
## 3	M3 - ROSE balanceado, threshold 0.3		0.3106	0.0263	0.9552	0.0513	0.7177

```
metricas_long <- resumen %>%
  select(Modelo, F1, AUC_ROC) %>%
  pivot_longer(cols = c(F1, AUC_ROC),
               names_to = "Metrica",
               values_to = "Valor")

ggplot(metricas_long, aes(x = Modelo, y = Valor, fill = Metrica)) +
  geom_bar(stat = "identity", position = "dodge") +
  scale_fill_manual(values = c("#1f77b4", "#d62728")) +
  labs(title = "Comparación de modelos - F1 y AUC-ROC",
       x = NULL, y = "Valor") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))
```




La tabla y gráfica muestran que los Modelos 2 y 3 (con ROSE) superan ampliamente al Modelo 1 en F1 y AUC-ROC, confirmando que el balanceo de clases es indispensable para este problema. La diferencia entre M2 y M3 refleja el trade-off entre precisión y recall según el threshold elegido.

12. Curvas ROC comparativas

```

plot(res1$roc, col = "#888888", lwd = 1.5,
     main = "Curvas ROC - Regresión Logística")
plot(res2$roc, col = "#1f77b4", lwd = 2, add = TRUE)
plot(res3$roc, col = "#d62728", lwd = 2, add = TRUE)
legend("bottomright",
     legend = c(
       paste0("M1 sin balancear (AUC=", round(res1$auc, 3), ")"),
       paste0("M2 ROSE t=0.5 (AUC=", round(res2$auc, 3), ")"),
       paste0("M3 ROSE t=0.3 (AUC=", round(res3$auc, 3), ")")
     ),
     col = c("#888888", "#1f77b4", "#d62728"),
     lwd = 2,
     cex = 0.85)

```



La curva ROC muestra el rendimiento del modelo a distintos thresholds. Un AUC cercano a 1 indica que el modelo distingue bien entre las clases. Los Modelos 2 y 3 comparten la misma curva ROC porque usan el mismo modelo entrenado — la diferencia está solo en el punto de operación (threshold) elegido sobre esa curva.

13. Modelo final seleccionado

```
cat("Modelo final: M2 - ROSE balanceado, threshold 0.5\n\n")
```

```
## Modelo final: M2 - ROSE balanceado, threshold 0.5
```

```
cat("Justificación: ofrece el mejor balance entre precisión y recall.\n")
```

```
## Justificación: ofrece el mejor balance entre precisión y recall.
```

```
cat("El threshold 0.5 es más conservador que 0.3 y evita un exceso\n")
```

```
## El threshold 0.5 es más conservador que 0.3 y evita un exceso
```

```
cat("de falsos positivos, manteniendo un F1 y AUC competitivos.\n\n")
```

```
## de falsos positivos, manteniendo un F1 y AUC competitivos.
```

```
print(res2$cm)
```

```
## Confusion Matrix and Statistics
```

```
##
```

```
##           Reference
```

```
## Prediction    No    Si
```

```
##           No 41772   315
```

```
##           Si 44691  1404
```

```
##
```

```
##           Accuracy : 0.4896
```

```
##           95% CI : (0.4863, 0.4929)
```

```
## No Information Rate : 0.9805
```

```
## P-Value [Acc > NIR] : 1
```

```
##
```

```
##           Kappa : 0.022
```

```
##
```

```
## McNemar's Test P-Value : <2e-16
```

```
##
```

```
##           Sensitivity : 0.81675
```

```
##           Specificity : 0.48312
```

```
## Pos Pred Value : 0.03046
```

```
## Neg Pred Value : 0.99252
```

```
## Prevalence : 0.01949
```

```
## Detection Rate : 0.01592
```

```
## Detection Prevalence : 0.52273
```

```
## Balanced Accuracy : 0.64994
```


```
##
```

```
## 'Positive' Class : Si
```

```
##
```

```
cm_df <- as.data.frame(res2$cm$table)
names(cm_df) <- c("Predicho", "Real", "Freq")

ggplot(cm_df, aes(x = Real, y = Predicho, fill = Freq)) +
  geom_tile(color = "white") +
  geom_text(aes(label = Freq), size = 5, fontface = "bold",
            color = "white") +
  scale_fill_gradient(low = "#4292c6", high = "#08306b") +
  labs(title = "Matriz de confusión - Modelo final (Regresión Logística)",
       x = "Valor real", y = "Valor predicho") +
  theme_minimal()
```



14. Interpretación de coeficientes

```
odds_ratios <- exp(coef(m2))
cat("Odds Ratios (ordenados de mayor a menor):\n")
```

```
## Odds Ratios (ordenados de mayor a menor):
```



```
print(round(sort(odds_ratios, decreasing = TRUE), 4))
```

##	SitioocuOtro	DepremEl Progreso	DepremIzabal
##	33.9764	3.6209	2.6481
##	DepremRetalhuleu	DepremZacapa	DepremSuchitepequez
##	2.2168	1.9906	1.8402
##	DepremExtranjero	DepremEscuintla	Añoreg
##	1.6718	1.6470	1.6235
##	DepremSan Marcos	DepremHuehuetenango	DepremQuetzaltenango
##	1.5464	1.3261	1.2855
##	DepremQuiche	DepremPeten	EscolamPrimaria
##	1.2755	1.2740	1.2471
##	DepremAlta Verapaz	DepremSolola	SitioocuDomicilio
##	1.2321	1.0774	0.9759
##	EscolamBásica	DepremBaja Verapaz	SitioocuCentro de salud
##	0.9737	0.9664	0.9254
##	PueblopmMestizo / Ladino	SitioocuHospital privado	DepremChiquimula
##	0.8348	0.7849	0.6624
##	DepremJutiapa	PueblopmXinka	DepremSacatepequez
##	0.6411	0.6114	0.5978
##	DepremChimaltenango	DepremJalapa	SitioocuVía Pública
##	0.5192	0.5154	0.4936
##	DepremTotonicapan	PueblopmOtro	EscolamDiversificado
##	0.4622	0.3034	0.1892
##	DepremSanta Rosa	SitioocuSeguro social	EscolamPost Grado
##	0.1620	0.0402	0.0000
##	EscolamUniversitario	PueblopmGarifuna	(Intercept)
##	0.0000	0.0000	0.0000

Los odds ratios indican el efecto de cada variable sobre la probabilidad de maternidad adolescente. Valores mayores a 1 aumentan la probabilidad y valores menores a 1 la reducen. Las variables educativas deberían mostrar los efectos más fuertes, consistente con los resultados del EDA del Proyecto 1 donde se identificó una relación inversa clara entre nivel educativo y maternidad temprana.