

Proyecto 2 – Maternidad Adolescente en Guatemala (2009–2023)

Grupo 6

2026-05-18

Contents

1. Librerías	2
2. Variable Respuesta	3
3. Carga de datos	3
4. Limpieza y construcción de variables	3
5. Selección de variables predictoras y dataset final	4
6. Análisis de desbalance	5
7. División Train / Test (70 / 30, estratificada)	6
8. Exportar datos para el grupo	7
9. Función auxiliar de métricas	7
10. Regresión Logística	8
Modelo 1 — Sin balancear, threshold 0.5	8
Modelo 2 — Con ROSE balanceado, threshold 0.5	10
Modelo 3 — Con ROSE balanceado, threshold 0.3	12
11. Comparación de modelos	13
12. Curvas ROC comparativas	14
13. Modelo final seleccionado	15
14. Interpretación de coeficientes	17

15. Random Forest	18
Función métricas para Random Forest	18
Modelo 1 — Sin balancear, 100 árboles	19
Modelo 2 — Con ROSE balanceado, 100 árboles	20
Modelo 3 — Con ROSE balanceado, 200 árboles	21
16. Comparación de modelos Random Forest	22
17. Curvas ROC comparativas – Random Forest	24
18. Modelo final seleccionado – Random Forest	25
19. Importancia de variables	27
20. Naive Bayes	28
Modelo 1 — Sin balancear	28
Modelo 2 - ROSE balanceado	32
Modelo 3 — ROSE + Laplace	33
22. Comparación global de algoritmos	34
23. Conclusiones finales	34

1. Librerías

```
library(haven)
library(dplyr)
library(tidyr)
library(ggplot2)
library(caret)
library(ROSE)
library(pROC)
library(randomForest)
library(e1071)
```

Instalar paquetes nuevos si es necesario: `install.packages(c("caret", "ROSE", "pROC", "tidyr"))`

2. Variable Respuesta

La variable respuesta es **adolescente** (binaria):

- 1 = nacimiento en madre menor de 18 años
- 0 = nacimiento en madre de 18 años o más

Es una variable **cualitativa / categórica binaria**, por lo que el problema es de **clasificación**. Se eligió esta variable porque fue el eje central del análisis exploratorio del Proyecto 1, donde se identificaron patrones territoriales, educativos y étnicos asociados al fenómeno. Predecir si un nacimiento corresponde a una madre adolescente permite identificar los factores más relevantes y diseñar intervenciones focalizadas.

3. Carga de datos

```
archivos <- list.files("Datos", pattern = "\\..sav$", full.names = TRUE)
df_test  <- read_sav(archivos[1])

lista_datos <- lapply(archivos, function(x) {
  df <- read_sav(x)
  df <- zap_labels(df)
  df[] <- lapply(df, as.character)
  df
})

datos_unidos <- bind_rows(lista_datos)
cat("Registros totales:", nrow(datos_unidos), "\n")
```

```
## Registros totales: 5195195
```

4. Limpieza y construcción de variables

```
# --- Año ---
datos_unidos$Añoereg <- ifelse(nchar(datos_unidos$Añoereg) == 1,
                              paste0("200", datos_unidos$Añoereg),
                              ifelse(nchar(datos_unidos$Añoereg) == 2,
                                      paste0("20", datos_unidos$Añoereg),
                                      datos_unidos$Añoereg))
datos_unidos$Añoereg <- as.numeric(datos_unidos$Añoereg)

# --- Edad materna ---
datos_unidos$Edadm <- as.numeric(datos_unidos$Edadm)
datos_unidos$Edadm[datos_unidos$Edadm == 999] <- NA
```



```
## $ Añoereg <dbl> 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022~
## $ Escolam <fct> Diversificado, Diversificado, Primaria, Primaria, Primaria~
## $ Pueblopm <fct> Mestizo / Ladino, Mestizo / Ladino, Mestizo / Ladino, Mest~
## $ Sitioocu <fct> Centro de salud, Centro de salud, Centro de salud, Centro ~
## $ Deprem <fct> Chimaltenango, Guatemala, Santa Rosa, Escuintla, Solola, Q~
```

Las variables seleccionadas son:

Variable	Descripción	Tipo
Añoereg	Año de registro del nacimiento	Númerica
Escolam	Nivel educativo de la madre	Categórica
Pueblopm	Grupo étnico de la madre	Categórica
Sitioocu	Lugar de ocurrencia del nacimiento	Categórica
Deprem	Departamento de residencia	Categórica

6. Análisis de desbalance

```
tabla_clase <- table(df_modelo$adolescente)
prop_clase <- prop.table(tabla_clase)


print(tabla_clase)
```

```
##
##      No      Si
## 288210  5733
```

```
print(round(prop_clase * 100, 2))
```

```
##
##      No      Si
## 98.05  1.95
```

```
ggplot(as.data.frame(prop_clase), aes(x = Var1, y = Freq, fill = Var1)) +
  geom_bar(stat = "identity") +
  scale_fill_manual(values = c("#4292c6", "#d62728")) +
  labs(title = "Distribución de la variable respuesta",
       x = "Maternidad adolescente", y = "Proporción") +
  theme_minimal() +
  theme(legend.position = "none")
```



El dataset presenta un desbalance severo: aproximadamente el 98% de los registros corresponden a madres no adolescentes y solo el 2% a madres menores de 18 años. Esto ocurre porque al filtrar las categorías “Ignorado” y NAs, muchos registros de madres adolescentes fueron eliminados junto con los demás.

Este desbalance tiene implicaciones directas en el modelado: un clasificador que prediga siempre “No” tendría ~98% de accuracy sin aprender nada útil. Por esta razón se utilizará oversampling (ROSE) para balancear el conjunto de entrenamiento, y se reportarán F1-score y AUC-ROC como métricas principales en lugar de accuracy.

7. División Train / Test (70 / 30, estratificada)

Se usa `createDataPartition` de `caret` para garantizar que ambas particiones conserven la misma proporción de la clase minoritaria.

```
set.seed(123)

idx_train <- createDataPartition(df_modelo$adolescente, p = 0.70, list = FALSE)

train_data <- df_modelo[ idx_train, ]
test_data  <- df_modelo[-idx_train, ]

cat("Registros en train:", nrow(train_data), "\n")
```

```
## Registros en train: 205761
```

```
cat("Registros en test: ", nrow(test_data), "\n")
```

```
## Registros en test: 88182
```

```
cat("\nProporción en TRAIN:\n")
```

```
##
```

```
## Proporción en TRAIN:
```

```
print(round(prop.table(table(train_data$adolescente)) * 100, 2))
```

```
##
```

```
##      No      Si
```

```
## 98.05  1.95
```

```
cat("\nProporción en TEST:\n")
```

```
##
```

```
## Proporción en TEST:
```

```
print(round(prop.table(table(test_data$adolescente)) * 100, 2))
```

```
##
```

```
##      No      Si
```

```
## 98.05  1.95
```

Se utilizó una división 70/30 estratificada. La estratificación garantiza que el desbalance original se preserve en ambas particiones, evitando que por azar una de ellas tenga una proporción distinta de la clase minoritaria. El conjunto de prueba no será modificado en ningún momento durante el entrenamiento.

8. Exportar datos para el grupo

```
saveRDS(train_data, "train_data.rds")
saveRDS(test_data, "test_data.rds")
cat("Archivos guardados: train_data.rds y test_data.rds\n")
```

```
## Archivos guardados: train_data.rds y test_data.rds
```

9. Función auxiliar de métricas

Para mantener consistencia entre los 3 modelos, se define una función que calcula accuracy, precisión, recall, F1-score y AUC-ROC sobre el conjunto de prueba.

```

evaluar_modelo <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {
  probs <- predict(modelo, newdata = datos_test, type = "response")
  preds <- factor(ifelse(probs >= threshold, "Si", "No"),
                  levels = c("No", "Si"))

  cm      <- confusionMatrix(preds, datos_test$adolescente, positive = "Si")
  roc_obj <- roc(as.numeric(datos_test$adolescente == "Si"), probs, quiet = TRUE)
  auc_val <- auc(roc_obj)

  cat("\n=====\\n")
  cat(" Modelo:", nombre_modelo, "\\n")
  cat(" Threshold:", threshold, "\\n")
  cat("=====\\n")
  print(cm$table)
  cat("\\nAccuracy :", round(cm$overall["Accuracy"], 4), "\\n")
  cat("Precision:", round(cm$byClass["Precision"], 4), "\\n")
  cat("Recall    :", round(cm$byClass["Recall"], 4), "\\n")
  cat("F1-score  :", round(cm$byClass["F1"], 4), "\\n")
  cat("AUC-ROC   :", round(auc_val, 4), "\\n")

  list(
    nombre      = nombre_modelo,
    threshold   = threshold,
    accuracy    = cm$overall["Accuracy"],
    precision    = cm$byClass["Precision"],
    recall      = cm$byClass["Recall"],
    f1          = cm$byClass["F1"],
    auc         = as.numeric(auc_val),
    roc         = roc_obj,
    cm          = cm
  )
}

```

10. Regresión Logística

La regresión logística es un algoritmo de clasificación binaria que modela la probabilidad de pertenecer a la clase positiva mediante una función sigmoide. Es interpretable, eficiente computacionalmente y sirve como línea base para comparar contra algoritmos más complejos. Maneja variables categóricas directamente como factores en R sin necesidad de codificación manual.

Modelo 1 — Sin balancear, threshold 0.5

Este modelo sirve como línea base. Se espera alta accuracy pero bajo recall en la clase “Si” debido al desbalance severo.

```

set.seed(123)

m1 <- glm(adolescente ~ .,
          data = train_data,

```



```
family = binomial(link = "logit"))

summary(m1)
```

```
##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -852.96734    77.55997 -10.998 < 2e-16 ***
## Añoreg           0.41991     0.03835  10.948 < 2e-16 ***
## EscolamPrimaria   0.24131     0.04208   5.735 9.78e-09 ***
## EscolamBásica    -0.00522     0.05535  -0.094 0.924859
## EscolamDiversificado -1.64355     0.09908 -16.589 < 2e-16 ***
## EscolamUniversitario -14.21779    96.43438  -0.147 0.882789
## EscolamPost Grado -14.07765   483.94503  -0.029 0.976793
## PueblopMGarifuna  -14.75348   899.96057  -0.016 0.986920
## PueblopMxinka     -0.43678     0.39678  -1.101 0.270977
## PueblopMestizo / Ladino -0.24523     0.04554  -5.385 7.24e-08 ***
## PueblopM Otro     -1.23155     0.19279  -6.388 1.68e-10 ***
## SitioocuHospital privado -0.25945     0.05816  -4.461 8.14e-06 ***
## SitioocuCentro de salud -0.15328     0.05838  -2.626 0.008647 **
## SitioocuSeguro social -3.26730     0.35545  -9.192 < 2e-16 ***
## SitioocuVía Pública -0.74742     0.71324  -1.048 0.294674
## SitioocuDomicilio  -0.08913     0.04028  -2.213 0.026914 *
## SitioocuOtro       2.02368     1.16931   1.731 0.083512 .
## DepremEl Progreso   1.33060     0.11994  11.094 < 2e-16 ***
## DepremSacatepequez -0.46309     0.20353  -2.275 0.022888 *
## DepremChimaltenango -0.66634     0.13363  -4.986 6.15e-07 ***
## DepremEscuintla     0.59208     0.10151   5.833 5.45e-09 ***
## DepremSanta Rosa   -1.86029     0.33984  -5.474 4.40e-08 ***
## DepremSolola        0.03317     0.11786   0.281 0.778358
## DepremTotonicapan  -0.70424     0.13595  -5.180 2.22e-07 ***
## DepremQuetzaltenango 0.19761     0.09738   2.029 0.042440 *
## DepremSuchitepequez 0.64916     0.09778   6.639 3.16e-11 ***
## DepremRetalhuleu    0.84637     0.11073   7.643 2.11e-14 ***
## DepremSan Marcos    0.42573     0.08175   5.208 1.91e-07 ***
## DepremHuehuetenango 0.31023     0.07891   3.932 8.44e-05 ***
## DepremQuiche        0.24765     0.08280   2.991 0.002780 **
## DepremBaja Verapaz -0.02470     0.13390  -0.184 0.853674
## DepremAlta Verapaz  0.27180     0.08155   3.333 0.000859 ***
## DepremPeten         0.32918     0.09457   3.481 0.000500 ***
## DepremIzabal        1.09977     0.08930  12.315 < 2e-16 ***
## DepremZacapa        0.78768     0.12137   6.490 8.58e-11 ***
## DepremChiquimula    -0.38458     0.13468  -2.855 0.004298 **
## DepremJalapa        -0.60053     0.17086  -3.515 0.000440 ***
## DepremJutiapa       -0.47058     0.16000  -2.941 0.003270 **
## DepremExtranjero    -0.02441     1.01219  -0.024 0.980758
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
```

```
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 39555 on 205760 degrees of freedom
## Residual deviance: 36898 on 205722 degrees of freedom
## AIC: 36976
##
## Number of Fisher Scoring iterations: 17
```

```
res1 <- evaluar_modelo(m1, test_data,
                       nombre_modelo = "M1 - Sin balancear, threshold 0.5")
```

```
##
## =====
## Modelo: M1 - Sin balancear, threshold 0.5
## Threshold: 0.5
## =====
##
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0     0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.7212
```

Como se esperaba, el modelo sin balancear tiene accuracy alta (~98%) pero un recall muy bajo para la clase “Si”. El modelo aprende a predecir casi siempre “No” porque esa clase domina el conjunto de entrenamiento. Esto confirma que accuracy no es una métrica adecuada para este problema y que es necesario corregir el desbalance.

Modelo 2 — Con ROSE balanceado, threshold 0.5

Se aplica oversampling con ROSE sobre el conjunto de entrenamiento para balancear las clases. El conjunto de prueba no se modifica, ya que debe representar la distribución real del fenómeno.

```
set.seed(123)

train_balanced <- ROSE(adolescente ~ ., data = train_data, seed = 123)$data

cat("Distribución en train balanceado:\n")
```

```
## Distribución en train balanceado:
```

```
print(table(train_balanced$adolescente))
```

```
##
##      No      Si
## 103155 102606
```

```
m2 <- glm(adolescente ~ .,
          data = train_balanced,
          family = binomial(link = "logit"))

summary(m2)
```

```
##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_balanced)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -979.86800    24.78122  -39.541 < 2e-16 ***
## Añoreg           0.48459     0.01225   39.543 < 2e-16 ***
## EscolamPrimaria  0.22085     0.01269   17.401 < 2e-16 ***
## EscolamBásica   -0.02664     0.01619   -1.646 0.099849 .
## EscolamDiversificado -1.66508     0.02313  -71.977 < 2e-16 ***
## EscolamUniversitario -15.06947    29.04741   -0.519 0.603908
## EscolamPost Grado -14.97642   146.76880   -0.102 0.918724
## PueblopmGarifuna -15.69870   259.97752   -0.060 0.951849
## PueblopmXinka    -0.49192     0.09836   -5.001 5.70e-07 ***
## PueblopmMestizo / Ladino -0.18059     0.01432  -12.615 < 2e-16 ***
## PueblopmOtro     -1.19260     0.04570  -26.094 < 2e-16 ***
## SitioocuHospital privado -0.24220     0.01639  -14.779 < 2e-16 ***
## SitioocuCentro de salud -0.07754     0.01736   -4.466 7.97e-06 ***
## SitioocuSeguro social -3.21317     0.07133  -45.046 < 2e-16 ***
## SitioocuVía Pública -0.70601     0.20033   -3.524 0.000425 ***
## SitioocuDomicilio -0.02435     0.01244   -1.957 0.050300 .
## SitioocuOtro      3.52567     1.01441    3.476 0.000510 ***
## DepremEl Progreso  1.28671     0.04222   30.476 < 2e-16 ***
## DepremSacatepequez -0.51457     0.05154   -9.984 < 2e-16 ***
## DepremChimaltenango -0.65554     0.03416  -19.190 < 2e-16 ***
## DepremEscuintla    0.49897     0.02967   16.815 < 2e-16 ***
## DepremSanta Rosa  -1.82015     0.06959  -26.157 < 2e-16 ***
## DepremSolola       0.07457     0.03379    2.207 0.027337 *
## DepremTotonicapan -0.77167     0.03544  -21.775 < 2e-16 ***
## DepremQuetzaltenango 0.25114     0.02789    9.003 < 2e-16 ***
## DepremSuchitepequez 0.60986     0.02942   20.733 < 2e-16 ***
## DepremRetalhuleu    0.79608     0.03486   22.833 < 2e-16 ***
## DepremSan Marcos   0.43591     0.02357   18.497 < 2e-16 ***
## DepremHuehuetenango 0.28228     0.02334   12.094 < 2e-16 ***
## DepremQuiche       0.24333     0.02445    9.953 < 2e-16 ***
## DepremBaja Verapaz -0.03414     0.03788   -0.901 0.367358
## DepremAlta Verapaz  0.20874     0.02412    8.653 < 2e-16 ***
## DepremPeten        0.24218     0.02750    8.806 < 2e-16 ***
## DepremIzabal       0.97384     0.02952   32.991 < 2e-16 ***
## DepremZacapa       0.68842     0.03785   18.190 < 2e-16 ***
## DepremChiquimula   -0.41194     0.03464  -11.891 < 2e-16 ***
## DepremJalapa       -0.66281     0.04198  -15.788 < 2e-16 ***
## DepremJutiapa      -0.44453     0.03914  -11.356 < 2e-16 ***
## DepremExtranjero   0.51389     0.23115    2.223 0.026203 *
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 285244  on 205760  degrees of freedom
## Residual deviance: 247111  on 205722  degrees of freedom
## AIC: 247189
##
## Number of Fisher Scoring iterations: 14
```

```
res2 <- evaluar_modelo(m2, test_data,
                       nombre_modelo = "M2 - ROSE balanceado, threshold 0.5")
```

```
##
## =====
##  Modelo: M2 - ROSE balanceado, threshold 0.5
##  Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 41772  315
##           Si 44691 1404
##
## Accuracy : 0.4896
## Precision: 0.0305
## Recall   : 0.8168
## F1-score : 0.0587
## AUC-ROC  : 0.7177
```

Al balancear las clases con ROSE, el recall mejora considerablemente. La accuracy baja porque el modelo ya no predice siempre “No”, lo cual es el comportamiento correcto. El F1-score y AUC-ROC son mejores indicadores de rendimiento en este contexto y deben ser las métricas de referencia para comparar modelos.

Modelo 3 — Con ROSE balanceado, threshold 0.3

Se mantiene el mismo modelo entrenado con ROSE pero se ajusta el threshold de decisión de 0.5 a 0.3. Al bajar el threshold, el modelo clasifica como “Si” con menor confianza requerida, lo que aumenta el recall a costa de algo de precisión. En contextos de salud pública suele preferirse detectar más casos verdaderos (mayor recall) aunque se generen más falsos positivos.

```
res3 <- evaluar_modelo(m2, test_data,
                       nombre_modelo = "M3 - ROSE balanceado, threshold 0.3",
                       threshold      = 0.3)
```

```
##
## =====
##  Modelo: M3 - ROSE balanceado, threshold 0.3
##  Threshold: 0.3
## =====
```

```
##           Reference
## Prediction    No    Si
##           No 25747    77
##           Si 60716 1642
##
## Accuracy : 0.3106
## Precision: 0.0263
## Recall   : 0.9552
## F1-score : 0.0513
## AUC-ROC  : 0.7177
```

Con threshold 0.3 el recall aumenta respecto al Modelo 2, detectando más casos de maternidad adolescente. Sin embargo, la precisión disminuye porque también aumentan los falsos positivos. Este trade-off es relevante para el problema: dependiendo del uso de los resultados, puede ser preferible detectar más casos a riesgo de generar algunas alertas innecesarias.

11. Comparación de modelos


```
resumen <- data.frame(
  Modelo = c(res1$nombre, res2$nombre, res3$nombre),
  Accuracy = round(c(res1$accuracy, res2$accuracy, res3$accuracy), 4),
  Precision = round(c(res1$precision, res2$precision, res3$precision), 4),
  Recall = round(c(res1$recall, res2$recall, res3$recall), 4),
  F1 = round(c(res1$f1, res2$f1, res3$f1), 4),
  AUC_ROC = round(c(res1$auc, res2$auc, res3$auc), 4)
)

print(resumen)
```

```
##           Modelo Accuracy Precision Recall    F1 AUC_ROC
## 1  M1 - Sin balancear, threshold 0.5   0.9805      NA 0.0000    NA  0.7212
## 2  M2 - ROSE balanceado, threshold 0.5   0.4896   0.0305 0.8168 0.0587  0.7177
## 3  M3 - ROSE balanceado, threshold 0.3   0.3106   0.0263 0.9552 0.0513  0.7177
```

```
metricas_long <- resumen %>%
  select(Modelo, F1, AUC_ROC) %>%
  pivot_longer(cols = c(F1, AUC_ROC),
    names_to = "Metrica",
    values_to = "Valor")


ggplot(metricas_long, aes(x = Modelo, y = Valor, fill = Metrica)) +
  geom_bar(stat = "identity", position = "dodge") +
  scale_fill_manual(values = c("#1f77b4", "#d62728")) +
  labs(title = "Comparación de modelos - F1 y AUC-ROC",
    x = NULL, y = "Valor") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))
```



La tabla y gráfica muestran que los Modelos 2 y 3 (con ROSE) superan ampliamente al Modelo 1 en F1 y AUC-ROC, confirmando que el balanceo de clases es indispensable para este problema. La diferencia entre M2 y M3 refleja el trade-off entre precisión y recall según el threshold elegido.

12. Curvas ROC comparativas

```
plot(res1$roc, col = "#888888", lwd = 1.5,
     main = "Curvas ROC - Regresión Logística")
plot(res2$roc, col = "#1f77b4", lwd = 2, add = TRUE)
plot(res3$roc, col = "#d62728", lwd = 2, add = TRUE)
legend("bottomright",
      legend = c(
        paste0("M1 sin balancear (AUC=", round(res1$auc, 3), ")"),
        paste0("M2 ROSE t=0.5 (AUC=", round(res2$auc, 3), ")"),
        paste0("M3 ROSE t=0.3 (AUC=", round(res3$auc, 3), ")")
      ),
      col = c("#888888", "#1f77b4", "#d62728"),
      lwd = 2,
      cex = 0.85)
```



La curva ROC muestra el rendimiento del modelo a distintos thresholds. Un AUC cercano a 1 indica que el modelo distingue bien entre las clases. Los Modelos 2 y 3 comparten la misma curva ROC porque usan el mismo modelo entrenado — la diferencia está solo en el punto de operación (threshold) elegido sobre esa curva.

13. Modelo final seleccionado

```
cat("Modelo final: M2 - ROSE balanceado, threshold 0.5\n\n")
```

```
## Modelo final: M2 - ROSE balanceado, threshold 0.5
```

```
cat("Justificación: ofrece el mejor balance entre precisión y recall.\n")
```

```
## Justificación: ofrece el mejor balance entre precisión y recall.
```

```
cat("El threshold 0.5 es más conservador que 0.3 y evita un exceso\n")
```

```
## El threshold 0.5 es más conservador que 0.3 y evita un exceso
```

```
cat("de falsos positivos, manteniendo un F1 y AUC competitivos.\n\n")
```

```
## de falsos positivos, manteniendo un F1 y AUC competitivos.
```


```
print(res2$cm)
```

```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction    No    Si
##           No 41772  315
##           Si 44691 1404
##
##           Accuracy : 0.4896
##           95% CI : (0.4863, 0.4929)
##           No Information Rate : 0.9805
##           P-Value [Acc > NIR] : 1
##
##           Kappa : 0.022
##
##           Mcnemar's Test P-Value : <2e-16
##
##           Sensitivity : 0.81675
##           Specificity : 0.48312
##           Pos Pred Value : 0.03046
##           Neg Pred Value : 0.99252
##           Prevalence : 0.01949
##           Detection Rate : 0.01592
##           Detection Prevalence : 0.52273
##           Balanced Accuracy : 0.64994
##
##           'Positive' Class : Si
##
```

```
cm_df <- as.data.frame(res2$cm$table)
names(cm_df) <- c("Predicho", "Real", "Freq")

ggplot(cm_df, aes(x = Real, y = Predicho, fill = Freq)) +
  geom_tile(color = "white") +
  geom_text(aes(label = Freq), size = 5, fontface = "bold",
            color = "white") +
  scale_fill_gradient(low = "#4292c6", high = "#08306b") +
  labs(title = "Matriz de confusión - Modelo final (Regresión Logística)",
       x = "Valor real", y = "Valor predicho") +
  theme_minimal()
```


Matriz de confusión – Modelo final (Regresión Logística)



14. Interpretación de coeficientes

```
odds_ratios <- exp(coef(m2))
cat("Odds Ratios (ordenados de mayor a menor):\n")
```

```
## Odds Ratios (ordenados de mayor a menor):
```

```
print(round(sort(odds_ratios, decreasing = TRUE), 4))
```

```
##      SitioocuOtro      DepremEl Progreso      DepremIzabal
##      33.9764      3.6209      2.6481
##      DepremRetalhuleu      DepremZacapa      DepremSuchitepequez
##      2.2168      1.9906      1.8402
##      DepremExtranjero      DepremEscuintla      Añoreg
##      1.6718      1.6470      1.6235
##      DepremSan Marcos      DepremHuehuetenango      DepremQuetzaltenango
##      1.5464      1.3261      1.2855
##      DepremQuiche      DepremPeten      EscolamPrimaria
##      1.2755      1.2740      1.2471
##      DepremAlta Verapaz      DepremSolola      SitioocuDomicilio
```

##	1.2321	1.0774	0.9759
##	EscolamBásica	DepremBaja Verapaz	SitioocuCentro de salud
##	0.9737	0.9664	0.9254
##	PueblopmMestizo / Ladino	SitioocuHospital privado	DepremChiquimula
##	0.8348	0.7849	0.6624
##	DepremJutiapa	PueblopmXinka	DepremSacatepequez
##	0.6411	0.6114	0.5978
##	DepremChimaltenango	DepremJalapa	SitioocuVía Pública
##	0.5192	0.5154	0.4936
##	DepremTotonicapan	PueblopmOtro	EscolamDiversificado
##	0.4622	0.3034	0.1892
##	DepremSanta Rosa	SitioocuSeguro social	EscolamPost Grado
##	0.1620	0.0402	0.0000
##	EscolamUniversitario	PueblopmGarifuna	(Intercept)
##	0.0000	0.0000	0.0000

Los odds ratios indican el efecto de cada variable sobre la probabilidad de maternidad adolescente. Valores mayores a 1 aumentan la probabilidad y valores menores a 1 la reducen. Las variables educativas deberían mostrar los efectos más fuertes, consistente con los resultados del EDA del Proyecto 1 donde se identificó una relación inversa clara entre nivel educativo y maternidad temprana.

15. Random Forest

La técnica Random Forest es un algoritmo de aprendizaje supervisado basado en múltiples árboles de decisión, donde entrena numerosos árboles sobre subconjuntos aleatorios de los datos y combina sus predicciones mediante votación. Este algoritmo es especialmente útil en problemas con relaciones no lineales y variables categóricas, además de ser robusto frente a datasets desbalanceados.

Debido a estas características, Random Forest ha sido ampliamente utilizado en problemas de clasificación en salud pública y análisis de riesgo.

Función métricas para Random Forest

```
evaluar_rf <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {

  probs <- predict(modelo, newdata = datos_test, type = "prob")[, "Si"]

  preds <- factor(ifelse(probs >= threshold, "Si", "No"),
                 levels = c("No", "Si"))

  cm <- confusionMatrix(preds, datos_test$adolescente,
                       positive = "Si")

  roc_obj <- roc(as.numeric(datos_test$adolescente == "Si"),
                probs,
                quiet = TRUE)

  auc_val <- auc(roc_obj)

  cat("\n=====n")
  cat(" Modelo:", nombre_modelo, "\n")
}
```

```

cat(" Threshold:", threshold, "\n")
cat("=====\n")

print(cm$table)

cat("\nAccuracy :", round(cm$overall["Accuracy"], 4), "\n")
cat("Precision:", round(cm$byClass["Precision"], 4), "\n")
cat("Recall    :", round(cm$byClass["Recall"], 4), "\n")
cat("F1-score  :", round(cm$byClass["F1"], 4), "\n")
cat("AUC-ROC   :", round(auc_val, 4), "\n")

list(
  nombre     = nombre_modelo,
  threshold  = threshold,
  accuracy   = cm$overall["Accuracy"],
  precision  = cm$byClass["Precision"],
  recall     = cm$byClass["Recall"],
  f1         = cm$byClass["F1"],
  auc        = as.numeric(auc_val),
  roc        = roc_obj,
  cm         = cm
)
}

```

Modelo 1 — Sin balancear, 100 árboles

```

set.seed(123)

rf1 <- randomForest(
  adolescente ~ .,
  data = train_data,
  ntree = 100
)

print(rf1)

##
## Call:
## randomForest(formula = adolescente ~ ., data = train_data, ntree = 100)
##              Type of random forest: classification
##              Number of trees: 100
## No. of variables tried at each split: 2
##
##              OOB estimate of  error rate: 1.95%
## Confusion matrix:
##              No Si class.error
## No 201747  0          0
## Si  4014  0          1

```

```
rf_res1 <- evaluar_rf(
  rf1,
  test_data,
  nombre_modelo = "RF1 - Sin balancear, 100 árboles"
)
```

```
##
## =====
## Modelo: RF1 - Sin balancear, 100 árboles
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0     0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.4999
```

El modelo entrenado sin balanceo clasificó la totalidad de los registros como clase mayoritaria (“No”), obteniendo un recall y F1-score nulos para la clase positiva. Aunque la accuracy alcanzó el 98%, esta métrica resulta engañosa dado el fuerte desbalance de clases (98%/2%).

El AUC-ROC de 0.4999 confirma que el modelo no posee capacidad discriminativa real, comportándose prácticamente como un clasificador aleatorio.

Estos resultados evidencian que Random Forest, al igual que la regresión logística, colapsa hacia la clase mayoritaria cuando los datos no han sido balanceados previamente.

Modelo 2 — Con ROSE balanceado, 100 árboles

```
set.seed(123)
```

```
rf2 <- randomForest(
  adolescente ~ .,
  data = train_balanced,
  ntree = 100
)
```

```
print(rf2)
```

```
##
## Call:
## randomForest(formula = adolescente ~ ., data = train_balanced,      ntree = 100)
##           Type of random forest: classification
##           Number of trees: 100
## No. of variables tried at each split: 2
##
```

```
##          OOB estimate of  error rate: 22.93%
## Confusion matrix:
##          No      Si class.error
## No 82814 20341   0.1971887
## Si 26850 75756   0.2616806
```

```
rf_res2 <- evaluar_rf(
  rf2,
  test_data,
  nombre_modelo = "RF2 - ROSE balanceado, 100 árboles"
)
```

```
##
## =====
## Modelo: RF2 - ROSE balanceado, 100 árboles
## Threshold: 0.5
## =====
##          Reference
## Prediction    No    Si
##          No 77718 1153
##          Si  8745  566
##
## Accuracy : 0.8878
## Precision: 0.0608
## Recall   : 0.3293
## F1-score : 0.1026
## AUC-ROC  : 0.7236
```

Luego de aplicar balanceo mediante ROSE, el modelo logró detectar casos positivos reales, elevando el recall a 0.3293 y el F1-score a 0.1026. El AUC-ROC de 0.7236 supera al obtenido con regresión logística balanceada (0.7177), lo que sugiere que Random Forest captura mejor las relaciones no lineales entre variables sociodemográficas.

La precisión del Random Forest continúa siendo baja (0.0608) como consecuencia directa del desbalance presente en el conjunto de prueba, que no fue modificado intencionalmente para reflejar la distribución real de la población.

Modelo 3 — Con ROSE balanceado, 200 árboles

```
set.seed(123)

rf3 <- randomForest(
  adolescente ~ .,
  data = train_balanced,
  ntree = 200
)

print(rf3)
```

```
##
## Call:
```

```
## randomForest(formula = adolescente ~ ., data = train_balanced, ntree = 200)
##           Type of random forest: classification
##           Number of trees: 200
## No. of variables tried at each split: 2
##
##           OOB estimate of  error rate: 22.85%
## Confusion matrix:
##           No      Si class.error
## No 82832 20323   0.1970142
## Si 26690 75916   0.2601212
```

```
rf_res3 <- evaluar_rf(
  rf3,
  test_data,
  nombre_modelo = "RF3 - ROSE balanceado, 200 árboles"
)
```

```
##
## =====
## Modelo: RF3 - ROSE balanceado, 200 árboles
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 77320 1133
##           Si  9143  586
##
## Accuracy : 0.8835
## Precision: 0.0602
## Recall   : 0.3409
## F1-score : 0.1024
## AUC-ROC  : 0.7285
```

Incrementar el número de árboles de 100 a 200 produjo mejoras moderadas: el recall aumentó a 0.3409 y el AUC-ROC alcanzó 0.7285, el más alto entre todos los modelos del proyecto. El error OOB se redujo levemente (22.85% vs 22.93%), indicando mayor estabilidad. Sin embargo, las ganancias son marginales, lo que sugiere que el modelo comienza a estabilizarse y que aumentar aún más los árboles generaría rendimientos decrecientes sin un costo computacional justificado.

16. Comparación de modelos Random Forest

```
resumen_rf <- data.frame(
  Modelo      = c(rf_res1$nombre, rf_res2$nombre, rf_res3$nombre),

  Accuracy    = c(
    round(rf_res1$accuracy, 4),
    round(rf_res2$accuracy, 4),
    round(rf_res3$accuracy, 4)
  ),
)
```

```

Precision = c(
  ifelse(is.na(rf_res1$precision), 0, round(rf_res1$precision, 4)),
  ifelse(is.na(rf_res2$precision), 0, round(rf_res2$precision, 4)),
  ifelse(is.na(rf_res3$precision), 0, round(rf_res3$precision, 4))
),

Recall = c(
  round(rf_res1$recall, 4),
  round(rf_res2$recall, 4),
  round(rf_res3$recall, 4)
),

F1 = c(
  ifelse(is.na(rf_res1$f1), 0, round(rf_res1$f1, 4)),
  ifelse(is.na(rf_res2$f1), 0, round(rf_res2$f1, 4)),
  ifelse(is.na(rf_res3$f1), 0, round(rf_res3$f1, 4))
),

AUC_ROC = c(
  round(rf_res1$auc, 4),
  round(rf_res2$auc, 4),
  round(rf_res3$auc, 4)
)
)

print(resumen_rf)

```

##		Modelo	Accuracy	Precision	Recall	F1	AUC_ROC
## 1	RF1 - Sin balancear, 100 árboles		0.9805	0.0000	0.0000	0.0000	0.4999
## 2	RF2 - ROSE balanceado, 100 árboles		0.8878	0.0608	0.3293	0.1026	0.7236
## 3	RF3 - ROSE balanceado, 200 árboles		0.8835	0.0602	0.3409	0.1024	0.7285


El balanceo mediante ROSE resultó indispensable: sin él, el modelo es inútil para el objetivo del proyecto. RF3 fue seleccionado como modelo final por presentar el mayor AUC-ROC y el mejor recall, métricas prioritarias en un problema de salud pública donde los falsos negativos representan casos de maternidad adolescente no detectados. La diferencia entre RF2 y RF3 es marginal, pero RF3 ofrece mayor estabilidad y generalización.

```

metricas_rf <- resumen_rf %>%
  select(Modelo, F1, AUC_ROC) %>%
  pivot_longer(cols = c(F1, AUC_ROC),
    names_to = "Metrica",
    values_to = "Valor")

ggplot(metricas_rf,
  aes(x = Modelo, y = Valor, fill = Metrica)) +
  geom_bar(stat = "identity", position = "dodge") +
  scale_fill_manual(values = c("#1f77b4", "#d62728")) +
  labs(title = "Comparación de modelos - Random Forest",
    x = NULL,
    y = "Valor") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))

```



17. Curvas ROC comparativas – Random Forest

```
plot(rf_res1$roc,
     col = "#888888",
     lwd = 1.5,
     main = "Curvas ROC - Random Forest")


plot(rf_res2$roc,
     col = "#1f77b4",
     lwd = 2,
     add = TRUE)

plot(rf_res3$roc,
     col = "#d62728",
     lwd = 2,
     add = TRUE)

legend("bottomright",
      legend = c(
        paste0("RF1 sin balancear (AUC=", round(rf_res1$auc, 3), ")"),
        paste0("RF2 ROSE 100 árboles (AUC=", round(rf_res2$auc, 3), ")"),
        paste0("RF3 ROSE 200 árboles (AUC=", round(rf_res3$auc, 3), ")")
      ),
      )
```



```
col = c("#888888", "#1f77b4", "#d62728"),
lwd = 2,
cex = 0.85)
```



Las curvas ROC reflejan con claridad el impacto del balanceo: RF1 se ubica prácticamente sobre la diagonal aleatoria (AUC cercano a 0.50), mientras que RF2 y RF3 muestran una capacidad discriminativa considerablemente superior. RF3 alcanzó el mejor AUC del proyecto (0.7285), superando tanto a RF1 como a todos los modelos de regresión logística evaluados.

Esto confirma que Random Forest con datos balanceados constituye el modelo más adecuado para este problema.

18. Modelo final seleccionado – Random Forest

```
# Modelo seleccionado: RF3 - ROSE balanceado, 200 árboles
print(rf_res3$cm)
```


```
## Confusion Matrix and Statistics
##
##           Reference
## Prediction    No    Si
##           No 77320 1133
##           Si  9143  586
##
```

```
##           Accuracy : 0.8835
##           95% CI : (0.8813, 0.8856)
##      No Information Rate : 0.9805
##      P-Value [Acc > NIR] : 1
##
##           Kappa : 0.0716
##
##  McNemar's Test P-Value : <2e-16
##
##           Sensitivity : 0.340896
##           Specificity : 0.894255
##      Pos Pred Value : 0.060232
##      Neg Pred Value : 0.985558
##           Prevalence : 0.019494
##      Detection Rate : 0.006645
##      Detection Prevalence : 0.110329
##      Balanced Accuracy : 0.617576
##
##      'Positive' Class : Si
##
```

```
cm_rf <- as.data.frame(rf_res3$cm$table)
names(cm_rf) <- c("Predicho", "Real", "Freq")

ggplot(cm_rf, aes(x = Real, y = Predicho, fill = Freq)) +
  geom_tile(color = "white") +
  geom_text(aes(label = Freq), size = 5, fontface = "bold", color = "white") +
  scale_fill_gradient(low = "#4292c6", high = "#08306b") +
  labs(title = "Matriz de confusión - Modelo final Random Forest (RF3)",
       x = "Valor real", y = "Valor predicho") +
  theme_minimal()
```

Matriz de confusión – Modelo final Random Forest (RF3)



RF3 — ROSE balanceado, 200 árboles. Este modelo es el seleccionado como modelo final entre los tres evaluados por alcanzar el mayor AUC-ROC del proyecto (0.7285) y el mejor recall entre los modelos Random Forest evaluados (0.3409), métricas prioritarias en un contexto de salud pública donde minimizar los falsos negativos es crítico.

La matriz de confusión muestra que el modelo identificó correctamente 586 casos de maternidad adolescente, con un recall notablemente superior al obtenido sin balanceo.


Si bien la precisión permanece baja (0.0602) como reflejo del desbalance real de la población en el conjunto de prueba, el modelo logra un equilibrio razonable entre sensibilidad y especificidad (Balanced Accuracy: 0.6176), superando en capacidad discriminativa a todos los modelos de regresión logística evaluados.

19. Importancia de variables

```
importance(rf3)
```

```
##          MeanDecreaseGini
## Añoereg      29383.665
## Escolam      7978.668
## Pueblopm     1359.527
## Sitioocu     4113.003
## Deprem       8283.621
```

```
varImpPlot(rf3,
           main = "Importancia de variables - Random Forest")
```



Año de registro resultó la variable más importante por amplio margen (Gini: 29,383), lo que indica que el riesgo de maternidad adolescente presenta una tendencia temporal significativa en los datos.

Le siguen departamento de residencia (8,283) y escolaridad materna (7,978), confirmando que la distribución geográfica y el nivel educativo son los factores sociodemográficos con mayor poder predictivo. El sitio de ocurrencia del parto contribuye de forma moderada (4,113), mientras que la pertenencia étnica mostró la menor importancia relativa (1,359), aunque sigue siendo un predictor relevante dentro del modelo.

Estos resultados son consistentes con los odds ratios obtenidos en la regresión logística, donde departamentos como Izabal y El Progreso, junto con niveles bajos de escolaridad, presentaron las asociaciones más fuertes con maternidad adolescente.

20. Naive Bayes

El algoritmo Naive Bayes es un clasificador probabilístico basado en el Teorema de Bayes. Asume independencia condicional entre las variables predictoras y calcula la probabilidad de pertenencia a cada clase. Es un modelo simple, rápido y especialmente útil en problemas de clasificación con variables categóricas.

Modelo 1 — Sin balancear

Este modelo se entrena utilizando el conjunto original sin corrección de desbalance. Se espera una accuracy alta pero bajo recall para la clase minoritaria.

```

set.seed(123)

idx_train <- createDataPartition(
  df_modelo$adolescente,
  p = 0.70,
  list = FALSE
)

train_data <- df_modelo[idx_train, ]
test_data <- df_modelo[-idx_train, ]

set.seed(123)

nb1 <- naiveBayes(
  adolescente ~ .,
  data = train_data
)

nb1

```

```

##
## Naive Bayes Classifier for Discrete Predictors
##
## Call:
## naiveBayes.default(x = X, y = Y, laplace = laplace)
##
## A-priori probabilities:
## Y
##      No      Si
## 0.98049193 0.01950807
##
## Conditional probabilities:
##      Añoreg
## Y      [,1]      [,2]
## No 2022.147 0.3545667
## Si 2022.238 0.4260145
##
##      Escolam
## Y      Ninguno      Primaria      Básica Diversificado Universitario
## No 0.1711351346 0.4268762361 0.1757597387 0.2042409553 0.0211205123
## Si 0.2030393622 0.5961634280 0.1689088191 0.0318883906 0.0000000000
##      Escolam
## Y      Post Grado
## No 0.0008674231
## Si 0.0000000000
##
##      Pueblopm
## Y      Maya      Garifuna      Xinka Mestizo / Ladino      Otro
## No 0.4549460463 0.0002329651 0.0046890412 0.5132567027 0.0268752447
## Si 0.5804683607 0.0000000000 0.0017438964 0.4108121574 0.0069755855
##
##      Sitioocu
## Y      Hospital público Hospital privado Centro de salud Seguro social

```

```

## No 4.126902e-01 1.658860e-01 8.683153e-02 7.807799e-02
## Si 4.583956e-01 9.566517e-02 9.666168e-02 1.993024e-03
## Sitioocu
## Y Vía Pública Domicilio Otro
## No 8.475962e-04 2.556469e-01 1.982681e-05
## Si 4.982561e-04 3.465371e-01 2.491281e-04
##
## Deprem
## Y Guatemala El Progreso Sacatepequez Chimaltenango Escuintla
## No 0.1517643385 0.0110534481 0.0156978790 0.0399708546 0.0400253783
## Si 0.0690084704 0.0254110613 0.0067264574 0.0186846039 0.0398604883
## Deprem
## Y Santa Rosa Solola Totonicapan Quetzaltenango Suchitepequez
## No 0.0237426083 0.0293337695 0.0367242140 0.0520949506 0.0350488483
## Si 0.0022421525 0.0274040857 0.0181863478 0.0460886896 0.0443447932
## Deprem
## Y Retalhuleu San Marcos Huehuetenango Quiche Baja Verapaz
## No 0.0216062692 0.0746727337 0.0995702538 0.0864944708 0.0203224831
## Si 0.0308918784 0.0924265072 0.1377678127 0.1150971599 0.0184354758
## Deprem
## Y Alta Verapaz Peten Izabal Zacapa Chiquimula
## No 0.0908068026 0.0419535359 0.0267860241 0.0155442212 0.0318022077
## Si 0.1280518186 0.0500747384 0.0645241654 0.0241654210 0.0179372197
## Deprem
## Y Jalapa Jutiapa Extranjero
## No 0.0255121514 0.0289620168 0.0005105404
## Si 0.0104633782 0.0119581465 0.0002491281

```

```

evaluar_nb <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {

  probs <- predict(
    modelo,
    newdata = datos_test,
    type = "raw"
  )[, "Si"]

  preds <- factor(
    ifelse(probs >= threshold, "Si", "No"),
    levels = c("No", "Si")
  )

  cm <- confusionMatrix(
    preds,
    datos_test$adolescente,
    positive = "Si"
  )

  roc_obj <- roc(
    as.numeric(datos_test$adolescente == "Si"),
    probs,
    quiet = TRUE
  )

  auc_val <- auc(roc_obj)

```

```

cat("\n===== \n")
cat(" Modelo:", nombre_modelo, "\n")
cat(" Threshold:", threshold, "\n")
cat("===== \n")

print(cm$table)

cat("\nAccuracy :", round(cm$overall["Accuracy"], 4), "\n")
cat("Precision:", round(cm$byClass["Precision"], 4), "\n")
cat("Recall    :", round(cm$byClass["Recall"], 4), "\n")
cat("F1-score :", round(cm$byClass["F1"], 4), "\n")
cat("AUC-ROC  :", round(auc_val, 4), "\n")

list(
  nombre      = nombre_modelo,
  threshold   = threshold,
  accuracy    = cm$overall["Accuracy"],
  precision    = cm$byClass["Precision"],
  recall      = cm$byClass["Recall"],
  f1          = cm$byClass["F1"],
  auc         = as.numeric(auc_val),
  roc         = roc_obj,
  cm          = cm
)
}

nb_res1 <- evaluar_nb(
  nb1,
  test_data,
  nombre_modelo = "NB1 - Sin balancear"
)

```

```

##
## =====
## Modelo: NB1 - Sin balancear
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0    0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.6959

```

Modelo 2 - ROSE balanceado

```
set.seed(123)

train_balanced_nb <- ROSE(
  adolescente ~ .,
  data = train_data,
  seed = 123
)$data

table(train_balanced_nb$adolescente)
```

```
##
##      No      Si
## 103155 102606
```

```
nb2 <- naiveBayes(
  adolescente ~ .,
  data = train_balanced_nb
)

nb_res2 <- evaluar_nb(
  nb2,
  test_data,
  nombre_modelo = "NB2 - ROSE balanceado"
)
```

```
##
## =====
## Modelo: NB2 - ROSE balanceado
## Threshold: 0.5
## =====
##           Reference
## Prediction   No    Si
##           No 47992  443
##           Si 38471 1276
##
## Accuracy : 0.5587
## Precision: 0.0321
## Recall   : 0.7423
## F1-score : 0.0615
## AUC-ROC  : 0.6959
```

Al aplicar ROSE al conjunto de entrenamiento, el modelo Naive Bayes mejoró significativamente su capacidad para detectar casos positivos. El recall aumentó de 0 a 0.7423, confirmando que el balanceo de clases permite al modelo aprender patrones asociados a la maternidad adolescente. Aunque la precisión sigue siendo baja debido al gran número de falsos positivos, el F1-score mejora respecto al modelo sin balancear, indicando un mejor equilibrio entre sensibilidad y precisión.

Modelo 3 — ROSE + Laplace

```
nb3 <- naiveBayes(
  adolescente ~ .,
  data = train_balanced_nb,
  laplace = 1
)

nb_res3 <- evaluar_nb(
  nb3,
  test_data,
  nombre_modelo = "NB3 - ROSE + Laplace"
)
```

```
##
## =====
## Modelo: NB3 - ROSE + Laplace
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 48013  443
##           Si 38450 1276
##
## Accuracy : 0.5589
## Precision: 0.0321
## Recall   : 0.7423
## F1-score : 0.0616
## AUC-ROC  : 0.6961
```

El suavizado de Laplace permitió evitar probabilidades iguales a cero en categorías poco frecuentes, mejorando ligeramente la estabilidad del modelo Naive Bayes. Aunque las mejoras numéricas respecto al Modelo 2 son pequeñas, el Modelo 3 obtuvo el mayor F1-score y AUC-ROC entre los modelos Naive Bayes evaluados, por lo que puede considerarse el mejor modelo dentro de esta familia.

21. Conclusiones - Naive Bayes

La aplicación de modelos de clasificación permitió evaluar distintos enfoques para predecir la probabilidad de maternidad adolescente utilizando variables sociodemográficas y territoriales derivadas de los registros de nacimientos. Debido al fuerte desbalance del dataset — aproximadamente 98% de casos “No” y 2% de casos “Si” — los modelos entrenados sin técnicas de balanceo mostraron un desempeño engañosamente alto en accuracy, pero fueron incapaces de detectar correctamente la clase minoritaria.

En la regresión logística, el Modelo 1 sin balancear obtuvo una accuracy cercana al 98%, pero un recall igual a 0, ya que clasificó prácticamente todos los registros como “No”. Esto confirmó que accuracy no es una métrica adecuada en problemas con clases altamente desbalanceadas. Al aplicar ROSE para balancear el conjunto de entrenamiento, los Modelos 2 y 3 lograron detectar la mayoría de los casos positivos. El Modelo 2, utilizando threshold 0.5, alcanzó un recall de 0.8168 y un F1-score de 0.0587, mientras que el Modelo 3, con threshold 0.3, incrementó el recall hasta 0.9552 a costa de una disminución en precisión y accuracy. Esto evidenció el trade-off entre sensibilidad y falsos positivos: reducir el threshold permite detectar más casos reales, pero también incrementa significativamente las alertas incorrectas.

Con el uso de ROSE, el Modelo 2 mejoró considerablemente su capacidad predictiva, alcanzando un recall de 0.7423 y un F1-score de 0.0615. Posteriormente, el Modelo 3 incorporó Laplace smoothing para evitar probabilidades nulas en categorías poco frecuentes. Aunque las mejoras fueron pequeñas, este modelo obtuvo el mejor desempeño dentro de la familia Naive Bayes, con un F1-score de 0.0616 y AUC-ROC de 0.6961, mostrando una ligera mejora en estabilidad y generalización.

Comparando ambas familias de modelos, la regresión logística con ROSE presentó el mayor recall global, especialmente al reducir el threshold, mientras que Naive Bayes logró un F1-score ligeramente superior con un comportamiento más estable. Sin embargo, todos los modelos mantuvieron precisiones bajas debido al gran número de falsos positivos generados al intentar detectar una clase tan minoritaria. Esto refleja la dificultad inherente del problema y la limitada separabilidad entre clases utilizando únicamente las variables disponibles.

En términos prácticos, los resultados muestran que el balanceo de clases es indispensable para modelar fenómenos raros como la maternidad adolescente. Los modelos balanceados fueron capaces de identificar patrones asociados a nivel educativo, grupo étnico, departamento y lugar de ocurrencia del nacimiento, variables que ya habían mostrado relevancia en el análisis exploratorio previo. Además, los odds ratios de la regresión logística confirmaron que niveles educativos más altos disminuyen significativamente la probabilidad de maternidad adolescente, mientras que ciertos departamentos presentan riesgos relativos mayores.

22. Comparación global de algoritmos

23. Conclusiones finales