

Proyecto 2 – Maternidad Adolescente en Guatemala (2009–2023)

Grupo 6

2026-05-18

Contents

1. Librerías	1
2. Variable Respuesta	2
3. Carga de datos	2
4. Limpieza y construcción de variables	2
5. Selección de variables predictoras y dataset final	3
6. Análisis de desbalance	4
7. División Train / Test (70 / 30, estratificada)	5
8. Exportar datos para el grupo	6
9. Función auxiliar de métricas	6
10. Regresión Logística	7
Modelo 1 — Sin balancear, threshold 0.5	7
Modelo 2 — Con ROSE balanceado, threshold 0.5	9
Modelo 3 — Con ROSE balanceado, threshold 0.3	11
11. Comparación de modelos	11
12. Curvas ROC comparativas	13
13. Modelo final seleccionado	14
14. Interpretación de coeficientes	15
15. Naive Bayes	16
Modelo 1 — Sin balancear	16
Modelo 2 - ROSE balanceado	19
Modelo 3 — ROSE + Laplace	20

1. Librerías

```
library(haven)
library(dplyr)
library(tidyr)
library(ggplot2)
library(caret)
library(ROSE)
library(pROC)
```

Instalar paquetes nuevos si es necesario: `install.packages(c("caret", "ROSE", "pROC", "tidyr"))`

2. Variable Respuesta

La variable respuesta es **adolescente** (binaria):

- 1 = nacimiento en madre menor de 18 años
- 0 = nacimiento en madre de 18 años o más

Es una variable **cualitativa / categórica binaria**, por lo que el problema es de **clasificación**. Se eligió esta variable porque fue el eje central del análisis exploratorio del Proyecto 1, donde se identificaron patrones territoriales, educativos y étnicos asociados al fenómeno. Predecir si un nacimiento corresponde a una madre adolescente permite identificar los factores más relevantes y diseñar intervenciones focalizadas.

3. Carga de datos

```
archivos <- list.files("Datos", pattern = "\\..sav$", full.names = TRUE)
df_test <- read_sav(archivos[1])

lista_datos <- lapply(archivos, function(x) {
  df <- read_sav(x)
  df <- zap_labels(df)
  df[] <- lapply(df, as.character)
  df
})

datos_unidos <- bind_rows(lista_datos)
cat("Registros totales:", nrow(datos_unidos), "\n")

## Registros totales: 5195195
```

4. Limpieza y construcción de variables

```
# --- Año ---
datos_unidos$Añoreg <- ifelse(nchar(datos_unidos$Añoreg) == 1,
                             paste0("200", datos_unidos$Añoreg),
                             ifelse(nchar(datos_unidos$Añoreg) == 2,
                                     paste0("20", datos_unidos$Añoreg),
                                     datos_unidos$Añoreg))
```

```

datos_unidos$Añoreg <- as.numeric(datos_unidos$Añoreg)

# --- Edad materna ---
datos_unidos$Edadm <- as.numeric(datos_unidos$Edadm)
datos_unidos$Edadm[datos_unidos$Edadm == 999] <- NA

# --- Variable respuesta ---
datos_unidos$adolescente <- ifelse(datos_unidos$Edadm < 18, 1, 0)

# --- Factores con etiquetas oficiales ---
labels_depto <- attr(df_test$Deprem, "labels")
labels_educ <- attr(df_test$Escolam, "labels")
labels_etnia <- attr(df_test$Pueblopm, "labels")
labels_sitio <- attr(df_test$Sitioocu, "labels")

datos_unidos$Deprem <- factor(datos_unidos$Deprem, levels = labels_depto, labels = names(labels_depto))
datos_unidos$Escolam <- factor(datos_unidos$Escolam, levels = labels_educ, labels = names(labels_educ))
datos_unidos$Pueblopm <- factor(datos_unidos$Pueblopm, levels = labels_etnia, labels = names(labels_etnia))
datos_unidos$Sitioocu <- factor(datos_unidos$Sitioocu, levels = labels_sitio, labels = names(labels_sitio))

```

5. Selección de variables predictoras y dataset final

Se seleccionan las variables con mayor poder explicativo identificadas en el EDA del Proyecto 1. Se excluyen registros con NA y categorías “Ignorado”.

```

df_modelo <- datos_unidos %>%
  select(adolescente, Añoreg, Escolam, Pueblopm, Sitioocu, Deprem) %>%
  filter(
    !is.na(adolescente),
    !is.na(Escalam),
    !is.na(Pueblopm),
    !is.na(Sitioocu),
    !is.na(Deprem),
    Escolam != "Ignorado",
    Pueblopm != "Ignorado",
    Sitioocu != "Ignorado",
    Deprem != "Ignorado"
  ) %>%
  mutate(
    adolescente = factor(adolescente, levels = c(0, 1), labels = c("No", "Si")),
    Añoreg      = as.numeric(Añoreg)
  )

df_modelo <- droplevels(df_modelo)

cat("Registros después de limpieza:", nrow(df_modelo), "\n")

## Registros después de limpieza: 293943

glimpse(df_modelo)

```

```

## Rows: 293,943
## Columns: 6

```

```
## $ adolescente <fct> No, No, No, No, Si, No, No, No, No, No, No, No, No, No, No~
## $ Añoreg <dbl> 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022, 2022~
## $ Escolam <fct> Diversificado, Diversificado, Primaria, Primaria, Primaria~
## $ Pueblopm <fct> Mestizo / Ladino, Mestizo / Ladino, Mestizo / Ladino, Mest~
## $ Sitioocu <fct> Centro de salud, Centro de salud, Centro de salud, Centro ~
## $ Deprem <fct> Chimaltenango, Guatemala, Santa Rosa, Escuintla, Solola, Q~
```

Las variables seleccionadas son:

Variable	Descripción	Tipo
Añoreg	Año de registro del nacimiento	Numérica
Escolam	Nivel educativo de la madre	Categórica
Pueblopm	Grupo étnico de la madre	Categórica
Sitioocu	Lugar de ocurrencia del nacimiento	Categórica
Deprem	Departamento de residencia	Categórica

6. Análisis de desbalance

```
tabla_clase <- table(df_modelo$adolescente)
prop_clase <- prop.table(tabla_clase)
```


```
print(tabla_clase)
```

```
##
##      No      Si
## 288210  5733
```

```
print(round(prop_clase * 100, 2))
```

```
##
##      No      Si
## 98.05  1.95
```

```
ggplot(as.data.frame(prop_clase), aes(x = Var1, y = Freq, fill = Var1)) +
  geom_bar(stat = "identity") +
  scale_fill_manual(values = c("#4292c6", "#d62728")) +
  labs(title = "Distribución de la variable respuesta",
       x = "Maternidad adolescente", y = "Proporción") +
  theme_minimal() +
  theme(legend.position = "none")
```



El dataset presenta un desbalance severo: aproximadamente el 98% de los registros corresponden a madres no adolescentes y solo el 2% a madres menores de 18 años. Esto ocurre porque al filtrar las categorías “Ignorado” y NAs, muchos registros de madres adolescentes fueron eliminados junto con los demás.

Este desbalance tiene implicaciones directas en el modelado: un clasificador que prediga siempre “No” tendría ~98% de accuracy sin aprender nada útil. Por esta razón se utilizará oversampling (ROSE) para balancear el conjunto de entrenamiento, y se reportarán F1-score y AUC-ROC como métricas principales en lugar de accuracy.

7. División Train / Test (70 / 30, estratificada)

Se usa `createDataPartition` de `caret` para garantizar que ambas particiones conserven la misma proporción de la clase minoritaria.

```
set.seed(123)

idx_train <- createDataPartition(df_modelo$adolescente, p = 0.70, list = FALSE)

train_data <- df_modelo[ idx_train, ]
test_data  <- df_modelo[-idx_train, ]

cat("Registros en train:", nrow(train_data), "\n")
```

```
## Registros en train: 205761
```

```

cat("Registros en test: ", nrow(test_data), "\n")

## Registros en test: 88182
cat("\nProporción en TRAIN:\n")

##
## Proporción en TRAIN:
print(round(prop.table(table(train_data$adolescente)) * 100, 2))

##
##      No      Si
## 98.05   1.95
cat("\nProporción en TEST:\n")

##
## Proporción en TEST:
print(round(prop.table(table(test_data$adolescente)) * 100, 2))

##
##      No      Si
## 98.05   1.95

```

Se utilizó una división 70/30 estratificada. La estratificación garantiza que el desbalance original se preserve en ambas particiones, evitando que por azar una de ellas tenga una proporción distinta de la clase minoritaria. El conjunto de prueba no será modificado en ningún momento durante el entrenamiento.

8. Exportar datos para el grupo

```

saveRDS(train_data, "train_data.rds")
saveRDS(test_data, "test_data.rds")
cat("Archivos guardados: train_data.rds y test_data.rds\n")

## Archivos guardados: train_data.rds y test_data.rds

```

9. Función auxiliar de métricas

Para mantener consistencia entre los 3 modelos, se define una función que calcula accuracy, precisión, recall, F1-score y AUC-ROC sobre el conjunto de prueba.

```

evaluar_modelo <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {
  probs <- predict(modelo, newdata = datos_test, type = "response")
  preds <- factor(ifelse(probs >= threshold, "Si", "No"),
                  levels = c("No", "Si"))

  cm      <- confusionMatrix(preds, datos_test$adolescente, positive = "Si")
  roc_obj <- roc(as.numeric(datos_test$adolescente == "Si"), probs, quiet = TRUE)
  auc_val <- auc(roc_obj)

  cat("\n===== \n")
}

```

```

cat(" Modelo:", nombre_modelo, "\n")
cat(" Threshold:", threshold, "\n")
cat("=====\n")
print(cm$table)
cat("\nAccuracy :", round(cm$overall["Accuracy"], 4), "\n")
cat("Precision:", round(cm$byClass["Precision"], 4), "\n")
cat("Recall    :", round(cm$byClass["Recall"], 4), "\n")
cat("F1-score :", round(cm$byClass["F1"], 4), "\n")
cat("AUC-ROC  :", round(auc_val, 4), "\n")

list(
  nombre     = nombre_modelo,
  threshold  = threshold,
  accuracy   = cm$overall["Accuracy"],
  precision  = cm$byClass["Precision"],
  recall     = cm$byClass["Recall"],
  f1         = cm$byClass["F1"],
  auc        = as.numeric(auc_val),
  roc        = roc_obj,
  cm         = cm
)
}

```

10. Regresión Logística

La regresión logística es un algoritmo de clasificación binaria que modela la probabilidad de pertenecer a la clase positiva mediante una función sigmoide. Es interpretable, eficiente computacionalmente y sirve como línea base para comparar contra algoritmos más complejos. Maneja variables categóricas directamente como factores en R sin necesidad de codificación manual.

Modelo 1 — Sin balancear, threshold 0.5

Este modelo sirve como línea base. Se espera alta accuracy pero bajo recall en la clase “Si” debido al desbalance severo.

```

set.seed(123)

m1 <- glm(adolescente ~ .,
  data    = train_data,
  family  = binomial(link = "logit"))

summary(m1)

##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_data)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -852.96734    77.55997  -10.998  < 2e-16 ***
## Añoereg        0.41991     0.03835   10.948  < 2e-16 ***

```

```

## EscolamPrimaria      0.24131      0.04208      5.735 9.78e-09 ***
## EscolamBásica        -0.00522      0.05535     -0.094 0.924859
## EscolamDiversificado -1.64355      0.09908    -16.589 < 2e-16 ***
## EscolamUniversitario -14.21779     96.43438    -0.147 0.882789
## EscolamPost Grado    -14.07765    483.94503    -0.029 0.976793
## PueblopmGarifuna     -14.75348    899.96057    -0.016 0.986920
## PueblopmXinka        -0.43678      0.39678     -1.101 0.270977
## PueblopmMestizo / Ladino -0.24523      0.04554     -5.385 7.24e-08 ***
## PueblopmOtro         -1.23155      0.19279     -6.388 1.68e-10 ***
## SitioocuHospital privado -0.25945      0.05816     -4.461 8.14e-06 ***
## SitioocuCentro de salud -0.15328      0.05838     -2.626 0.008647 **
## SitioocuSeguro social -3.26730      0.35545     -9.192 < 2e-16 ***
## SitioocuVía Pública  -0.74742      0.71324     -1.048 0.294674
## SitioocuDomicilio    -0.08913      0.04028     -2.213 0.026914 *
## SitioocuOtro         2.02368      1.16931      1.731 0.083512 .
## DepremEl Progreso     1.33060      0.11994     11.094 < 2e-16 ***
## DepremSacatepequez   -0.46309      0.20353     -2.275 0.022888 *
## DepremChimaltenango  -0.66634      0.13363     -4.986 6.15e-07 ***
## DepremEscuintla       0.59208      0.10151      5.833 5.45e-09 ***
## DepremSanta Rosa     -1.86029      0.33984     -5.474 4.40e-08 ***
## DepremSolola          0.03317      0.11786      0.281 0.778358
## DepremTotonicapan    -0.70424      0.13595     -5.180 2.22e-07 ***
## DepremQuetzaltenango  0.19761      0.09738      2.029 0.042440 *
## DepremSuchitepequez   0.64916      0.09778      6.639 3.16e-11 ***
## DepremRetalhuleu      0.84637      0.11073      7.643 2.11e-14 ***
## DepremSan Marcos      0.42573      0.08175      5.208 1.91e-07 ***
## DepremHuehuetenango   0.31023      0.07891      3.932 8.44e-05 ***
## DepremQuiche          0.24765      0.08280      2.991 0.002780 **
## DepremBaja Verapaz    -0.02470      0.13390     -0.184 0.853674
## DepremAlta Verapaz    0.27180      0.08155      3.333 0.000859 ***
## DepremPeten           0.32918      0.09457      3.481 0.000500 ***
## DepremIzabal          1.09977      0.08930     12.315 < 2e-16 ***
## DepremZacapa          0.78768      0.12137      6.490 8.58e-11 ***
## DepremChiquimula     -0.38458      0.13468     -2.855 0.004298 **
## DepremJalapa          -0.60053      0.17086     -3.515 0.000440 ***
## DepremJutiapa         -0.47058      0.16000     -2.941 0.003270 **
## DepremExtranjero      -0.02441      1.01219     -0.024 0.980758
## ---

```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
## (Dispersion parameter for binomial family taken to be 1)
```

```
## Null deviance: 39555 on 205760 degrees of freedom
```

```
## Residual deviance: 36898 on 205722 degrees of freedom
```

```
## AIC: 36976
```

```
##
```

```
## Number of Fisher Scoring iterations: 17
```

```
res1 <- evaluar_modelo(m1, test_data,
                        nombre_modelo = "M1 - Sin balancear, threshold 0.5")
```

```
##
```

```
## =====
```

```
## Modelo: M1 - Sin balancear, threshold 0.5
```

```
## Threshold: 0.5
```



```
## =====
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0    0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.7212
```

Como se esperaba, el modelo sin balancear tiene accuracy alta (~98%) pero un recall muy bajo para la clase “Si”. El modelo aprende a predecir casi siempre “No” porque esa clase domina el conjunto de entrenamiento. Esto confirma que accuracy no es una métrica adecuada para este problema y que es necesario corregir el desbalance.

Modelo 2 — Con ROSE balanceado, threshold 0.5

Se aplica oversampling con ROSE sobre el conjunto de entrenamiento para balancear las clases. El conjunto de prueba no se modifica, ya que debe representar la distribución real del fenómeno.

```
set.seed(123)

train_balanced <- ROSE(adolescente ~ ., data = train_data, seed = 123)$data

cat("Distribución en train balanceado:\n")

## Distribución en train balanceado:
print(table(train_balanced$adolescente))

##
##      No      Si
## 103155 102606

m2 <- glm(adolescente ~ .,
          data = train_balanced,
          family = binomial(link = "logit"))

summary(m2)

##
## Call:
## glm(formula = adolescente ~ ., family = binomial(link = "logit"),
##      data = train_balanced)
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)   -979.86800    24.78122  -39.541 < 2e-16 ***
## Añoereg         0.48459     0.01225   39.543 < 2e-16 ***
## EscolamPrimaria 0.22085     0.01269   17.401 < 2e-16 ***
## EscolamBásica  -0.02664     0.01619   -1.646 0.099849 .
## EscolamDiversificado -1.66508    0.02313  -71.977 < 2e-16 ***
## EscolamUniversitario -15.06947    29.04741   -0.519 0.603908
```

```

## EscolamPost Grado      -14.97642  146.76880  -0.102  0.918724
## PueblopmGarifuna      -15.69870  259.97752  -0.060  0.951849
## PueblopmXinka         -0.49192    0.09836  -5.001  5.70e-07 ***
## PueblopmMestizo / Ladino -0.18059    0.01432 -12.615 < 2e-16 ***
## PueblopmOtro          -1.19260    0.04570 -26.094 < 2e-16 ***
## SitioocuHospital privado -0.24220    0.01639 -14.779 < 2e-16 ***
## SitioocuCentro de salud -0.07754    0.01736  -4.466  7.97e-06 ***
## SitioocuSeguro social  -3.21317    0.07133 -45.046 < 2e-16 ***
## SitioocuVía Pública    -0.70601    0.20033  -3.524  0.000425 ***
## SitioocuDomicilio      -0.02435    0.01244  -1.957  0.050300 .
## SitioocuOtro           3.52567    1.01441   3.476  0.000510 ***
## DepremEl Progreso      1.28671    0.04222  30.476 < 2e-16 ***
## DepremSacatepequez    -0.51457    0.05154  -9.984 < 2e-16 ***
## DepremChimaltenango   -0.65554    0.03416 -19.190 < 2e-16 ***
## DepremEscuintla       0.49897    0.02967  16.815 < 2e-16 ***
## DepremSanta Rosa      -1.82015    0.06959 -26.157 < 2e-16 ***
## DepremSolola           0.07457    0.03379   2.207  0.027337 *
## DepremTotonicapan     -0.77167    0.03544 -21.775 < 2e-16 ***
## DepremQuetzaltenango   0.25114    0.02789   9.003 < 2e-16 ***
## DepremSuchitepequez    0.60986    0.02942  20.733 < 2e-16 ***
## DepremRetalhuleu       0.79608    0.03486  22.833 < 2e-16 ***
## DepremSan Marcos       0.43591    0.02357  18.497 < 2e-16 ***
## DepremHuehuetenango    0.28228    0.02334  12.094 < 2e-16 ***
## DepremQuiche           0.24333    0.02445   9.953 < 2e-16 ***
## DepremBaja Verapaz     -0.03414    0.03788  -0.901  0.367358
## DepremAlta Verapaz     0.20874    0.02412   8.653 < 2e-16 ***
## DepremPeten            0.24218    0.02750   8.806 < 2e-16 ***
## DepremIzabal           0.97384    0.02952  32.991 < 2e-16 ***
## DepremZacapa           0.68842    0.03785  18.190 < 2e-16 ***
## DepremChiquimula      -0.41194    0.03464 -11.891 < 2e-16 ***
## DepremJalapa           -0.66281    0.04198 -15.788 < 2e-16 ***
## DepremJutiapa         -0.44453    0.03914 -11.356 < 2e-16 ***
## DepremExtranjero       0.51389    0.23115   2.223  0.026203 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##    Null deviance: 285244  on 205760  degrees of freedom
## Residual deviance: 247111  on 205722  degrees of freedom
## AIC: 247189
##
## Number of Fisher Scoring iterations: 14
res2 <- evaluar_modelo(m2, test_data,
                       nombre_modelo = "M2 - ROSE balanceado, threshold 0.5")

##
## =====
## Modelo: M2 - ROSE balanceado, threshold 0.5
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 41772  315

```

```
##           Si 44691 1404
##
## Accuracy : 0.4896
## Precision: 0.0305
## Recall   : 0.8168
## F1-score : 0.0587
## AUC-ROC  : 0.7177
```

Al balancear las clases con ROSE, el recall mejora considerablemente. La accuracy baja porque el modelo ya no predice siempre “No”, lo cual es el comportamiento correcto. El F1-score y AUC-ROC son mejores indicadores de rendimiento en este contexto y deben ser las métricas de referencia para comparar modelos.

Modelo 3 — Con ROSE balanceado, threshold 0.3

Se mantiene el mismo modelo entrenado con ROSE pero se ajusta el threshold de decisión de 0.5 a 0.3. Al bajar el threshold, el modelo clasifica como “Si” con menor confianza requerida, lo que aumenta el recall a costa de algo de precisión. En contextos de salud pública suele preferirse detectar más casos verdaderos (mayor recall) aunque se generen más falsos positivos.

```
res3 <- evaluar_modelo(m2, test_data,
                        nombre_modelo = "M3 - ROSE balanceado, threshold 0.3",
                        threshold      = 0.3)
```

```
##
## =====
## Modelo: M3 - ROSE balanceado, threshold 0.3
## Threshold: 0.3
## =====
##           Reference
## Prediction    No    Si
##           No 25747    77
##           Si 60716 1642
##
## Accuracy : 0.3106
## Precision: 0.0263
## Recall   : 0.9552
## F1-score : 0.0513
## AUC-ROC  : 0.7177
```

Con threshold 0.3 el recall aumenta respecto al Modelo 2, detectando más casos de maternidad adolescente. Sin embargo, la precisión disminuye porque también aumentan los falsos positivos. Este trade-off es relevante para el problema: dependiendo del uso de los resultados, puede ser preferible detectar más casos a riesgo de generar algunas alertas innecesarias.

11. Comparación de modelos

```
resumen <- data.frame(
  Modelo      = c(res1$nombre, res2$nombre, res3$nombre),
  Accuracy    = round(c(res1$accuracy, res2$accuracy, res3$accuracy), 4),
  Precision    = round(c(res1$precision, res2$precision, res3$precision), 4),
  Recall      = round(c(res1$recall, res2$recall, res3$recall), 4),
  F1          = round(c(res1$f1, res2$f1, res3$f1), 4),
```

```

AUC_ROC = round(c(res1$auc, res2$auc, res3$auc), 4)
)


print(resumen)

##               Modelo Accuracy Precision Recall      F1 AUC_ROC
## 1  M1 - Sin balancear, threshold 0.5   0.9805         NA 0.0000     NA 0.7212
## 2  M2 - ROSE balanceado, threshold 0.5   0.4896    0.0305 0.8168 0.0587 0.7177
## 3  M3 - ROSE balanceado, threshold 0.3   0.3106    0.0263 0.9552 0.0513 0.7177

metricas_long <- resumen %>%
  select(Modelo, F1, AUC_ROC) %>%
  pivot_longer(cols = c(F1, AUC_ROC),
               names_to = "Metrica",
               values_to = "Valor")

ggplot(metricas_long, aes(x = Modelo, y = Valor, fill = Metrica)) +
  geom_bar(stat = "identity", position = "dodge") +
  scale_fill_manual(values = c("#1f77b4", "#d62728")) +
  labs(title = "Comparación de modelos - F1 y AUC-ROC",
       x = NULL, y = "Valor") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))


```



La tabla y gráfica muestran que los Modelos 2 y 3 (con ROSE) superan ampliamente al Modelo 1 en F1 y AUC-ROC, confirmando que el balanceo de clases es indispensable para este problema. La diferencia entre M2 y M3 refleja el trade-off entre precisión y recall según el threshold elegido.

12. Curvas ROC comparativas

```
plot(res1$roc, col = "#888888", lwd = 1.5,
     main = "Curvas ROC - Regresión Logística")
plot(res2$roc, col = "#1f77b4", lwd = 2, add = TRUE)
plot(res3$roc, col = "#d62728", lwd = 2, add = TRUE)
legend("bottomright",
     legend = c(
       paste0("M1 sin balancear (AUC=", round(res1$auc, 3), ")"),
       paste0("M2 ROSE t=0.5 (AUC=", round(res2$auc, 3), ")"),
       paste0("M3 ROSE t=0.3 (AUC=", round(res3$auc, 3), ")")
     ),
     col = c("#888888", "#1f77b4", "#d62728"),
     lwd = 2,
     cex = 0.85)
```



La curva ROC muestra el rendimiento del modelo a distintos thresholds. Un AUC cercano a 1 indica que el modelo distingue bien entre las clases. Los Modelos 2 y 3 comparten la misma curva ROC porque usan el mismo modelo entrenado — la diferencia está solo en el punto de operación (threshold) elegido sobre esa curva.

13. Modelo final seleccionado

```
cat("Modelo final: M2 - ROSE balanceado, threshold 0.5\n\n")

## Modelo final: M2 - ROSE balanceado, threshold 0.5
cat("Justificación: ofrece el mejor balance entre precisión y recall.\n")

## Justificación: ofrece el mejor balance entre precisión y recall.
cat("El threshold 0.5 es más conservador que 0.3 y evita un exceso\n")

## El threshold 0.5 es más conservador que 0.3 y evita un exceso
cat("de falsos positivos, manteniendo un F1 y AUC competitivos.\n\n")


## de falsos positivos, manteniendo un F1 y AUC competitivos.
print(res2$cm)

## Confusion Matrix and Statistics
##
##           Reference
## Prediction    No    Si
##           No 41772   315
##           Si 44691  1404
##
##           Accuracy : 0.4896
##           95% CI : (0.4863, 0.4929)
##       No Information Rate : 0.9805
##       P-Value [Acc > NIR] : 1
##
##           Kappa : 0.022
##
##  Mcnemar's Test P-Value : <2e-16
##
##           Sensitivity : 0.81675
##           Specificity : 0.48312
##           Pos Pred Value : 0.03046
##           Neg Pred Value : 0.99252
##           Prevalence : 0.01949
##           Detection Rate : 0.01592
##       Detection Prevalence : 0.52273
##           Balanced Accuracy : 0.64994
##
##           'Positive' Class : Si
##
cm_df <- as.data.frame(res2$cm$table)
names(cm_df) <- c("Predicho", "Real", "Freq")

ggplot(cm_df, aes(x = Real, y = Predicho, fill = Freq)) +
  geom_tile(color = "white") +
  geom_text(aes(label = Freq), size = 5, fontface = "bold",
            color = "white") +
  scale_fill_gradient(low = "#4292c6", high = "#08306b") +
  labs(title = "Matriz de confusión - Modelo final (Regresión Logística)",
```

```
x = "Valor real", y = "Valor predicho") +  
theme_minimal()
```

Matriz de confusión – Modelo final (Regresión Logística)



14. Interpretación de coeficientes

```
odds_ratios <- exp(coef(m2))  
cat("Odds Ratios (ordenados de mayor a menor):\n")
```

```
## Odds Ratios (ordenados de mayor a menor):
```

```
print(round(sort(odds_ratios, decreasing = TRUE), 4))
```

```
##          SitioocuOtro      DepremEl Progreso      DepremIzabal  
##          33.9764          3.6209          2.6481  
##      DepremRetalhuleu      DepremZacapa      DepremSuchitepequez  
##          2.2168          1.9906          1.8402  
##      DepremExtranjero      DepremEscuintla      Añoreg  
##          1.6718          1.6470          1.6235  
##      DepremSan Marcos      DepremHuehuetenango      DepremQuetzaltenango  
##          1.5464          1.3261          1.2855  
##      DepremQuiche      DepremPeten      EscolamPrimaria  
##          1.2755          1.2740          1.2471  
##      DepremAlta Verapaz      DepremSolola      SitioocuDomicilio  
##          1.2321          1.0774          0.9759
```

##	EscolamBásica	DepremBaja Verapaz	SitioocuCentro de salud
##	0.9737	0.9664	0.9254
##	PueblopMestizo / Ladino	SitioocuHospital privado	DepremChiquimula
##	0.8348	0.7849	0.6624
##	DepremJutiapa	PueblopMxinka	DepremSacatepequez
##	0.6411	0.6114	0.5978
##	DepremChimaltenango	DepremJalapa	SitioocuVía Pública
##	0.5192	0.5154	0.4936
##	DepremTotonicapan	PueblopOtro	EscolamDiversificado
##	0.4622	0.3034	0.1892
##	DepremSanta Rosa	SitioocuSeguro social	EscolamPost Grado
##	0.1620	0.0402	0.0000
##	EscolamUniversitario	PueblopMGarifuna	(Intercept)
##	0.0000	0.0000	0.0000

Los odds ratios indican el efecto de cada variable sobre la probabilidad de maternidad adolescente. Valores mayores a 1 aumentan la probabilidad y valores menores a 1 la reducen. Las variables educativas deberían mostrar los efectos más fuertes, consistente con los resultados del EDA del Proyecto 1 donde se identificó una relación inversa clara entre nivel educativo y maternidad temprana.

```
library(e1071)
```

15. Naive Bayes

El algoritmo Naive Bayes es un clasificador probabilístico basado en el Teorema de Bayes. Asume independencia condicional entre las variables predictoras y calcula la probabilidad de pertenencia a cada clase. Es un modelo simple, rápido y especialmente útil en problemas de clasificación con variables categóricas.

Modelo 1 — Sin balancear

Este modelo se entrena utilizando el conjunto original sin corrección de desbalance. Se espera una accuracy alta pero bajo recall para la clase minoritaria.

```
library(caret)
set.seed(123)

idx_train <- createDataPartition(
  df_modelo$adolescente,
  p = 0.70,
  list = FALSE
)

train_data <- df_modelo[idx_train, ]
test_data <- df_modelo[-idx_train, ]

library(e1071)

set.seed(123)

nb1 <- naiveBayes(
  adolescente ~ .,
  data = train_data
)

nb1
```



```

##
## Naive Bayes Classifier for Discrete Predictors
##
## Call:
## naiveBayes.default(x = X, y = Y, laplace = laplace)
##
## A-priori probabilities:
## Y
##      No      Si
## 0.98049193 0.01950807
##
## Conditional probabilities:
##      Añoreg
## Y      [,1]      [,2]
## No 2022.147 0.3545667
## Si 2022.238 0.4260145
##
##      Escolam
## Y      Ninguno      Primaria      Básica Diversificado Universitario
## No 0.1711351346 0.4268762361 0.1757597387 0.2042409553 0.0211205123
## Si 0.2030393622 0.5961634280 0.1689088191 0.0318883906 0.0000000000
##      Escolam
## Y      Post Grado
## No 0.0008674231
## Si 0.0000000000
##
##      Pueblopm
## Y      Maya      Garifuna      Xinka Mestizo / Ladino      Otro
## No 0.4549460463 0.0002329651 0.0046890412 0.5132567027 0.0268752447
## Si 0.5804683607 0.0000000000 0.0017438964 0.4108121574 0.0069755855
##
##      Sitioocu
## Y      Hospital público Hospital privado Centro de salud Seguro social
## No 4.126902e-01 1.658860e-01 8.683153e-02 7.807799e-02
## Si 4.583956e-01 9.566517e-02 9.666168e-02 1.993024e-03
##      Sitioocu
## Y      Vía Pública      Domicilio      Otro
## No 8.475962e-04 2.556469e-01 1.982681e-05
## Si 4.982561e-04 3.465371e-01 2.491281e-04
##
##      Deprem
## Y      Guatemala El Progreso Sacatepequez Chimaltenango Escuintla
## No 0.1517643385 0.0110534481 0.0156978790 0.0399708546 0.0400253783
## Si 0.0690084704 0.0254110613 0.0067264574 0.0186846039 0.0398604883
##      Deprem
## Y      Santa Rosa      Solola      Totonicapan Quetzaltenango Suchitepequez
## No 0.0237426083 0.0293337695 0.0367242140 0.0520949506 0.0350488483
## Si 0.0022421525 0.0274040857 0.0181863478 0.0460886896 0.0443447932
##      Deprem
## Y      Retalhuleu San Marcos Huehuetenango Quiche Baja Verapaz
## No 0.0216062692 0.0746727337 0.0995702538 0.0864944708 0.0203224831
## Si 0.0308918784 0.0924265072 0.1377678127 0.1150971599 0.0184354758
##      Deprem
## Y      Alta Verapaz      Peten      Izabal      Zacapa      Chiquimula

```

```

## No 0.0908068026 0.0419535359 0.0267860241 0.0155442212 0.0318022077
## Si 0.1280518186 0.0500747384 0.0645241654 0.0241654210 0.0179372197
## Deprem
## Y Jalapa Jutiapa Extranjero
## No 0.0255121514 0.0289620168 0.0005105404
## Si 0.0104633782 0.0119581465 0.0002491281

evaluar_nb <- function(modelo, datos_test, nombre_modelo, threshold = 0.5) {

  probs <- predict(
    modelo,
    newdata = datos_test,
    type = "raw"
  )[, "Si"]

  preds <- factor(
    ifelse(probs >= threshold, "Si", "No"),
    levels = c("No", "Si")
  )

  cm <- confusionMatrix(
    preds,
    datos_test$adolescente,
    positive = "Si"
  )

  roc_obj <- roc(
    as.numeric(datos_test$adolescente == "Si"),
    probs,
    quiet = TRUE
  )

  auc_val <- auc(roc_obj)

  cat("\n===== \n")
  cat(" Modelo:", nombre_modelo, "\n")
  cat(" Threshold:", threshold, "\n")
  cat("===== \n")

  print(cm$table)

  cat("\nAccuracy :", round(cm$overall["Accuracy"], 4), "\n")
  cat("Precision:", round(cm$byClass["Precision"], 4), "\n")
  cat("Recall :", round(cm$byClass["Recall"], 4), "\n")
  cat("F1-score :", round(cm$byClass["F1"], 4), "\n")
  cat("AUC-ROC :", round(auc_val, 4), "\n")

  list(
    nombre = nombre_modelo,
    threshold = threshold,
    accuracy = cm$overall["Accuracy"],
    precision = cm$byClass["Precision"],
    recall = cm$byClass["Recall"],
    f1 = cm$byClass["F1"],
  )
}

```

```

    auc      = as.numeric(auc_val),
    roc      = roc_obj,
    cm       = cm
  )
}

nb_res1 <- evaluar_nb(
  nb1,
  test_data,
  nombre_modelo = "NB1 - Sin balancear"
)

```

```

##
## =====
## Modelo: NB1 - Sin balancear
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 86463 1719
##           Si     0    0
##
## Accuracy : 0.9805
## Precision: NA
## Recall   : 0
## F1-score : NA
## AUC-ROC  : 0.6959

```

Modelo 2 - ROSE balanceado

```

set.seed(123)

train_balanced_nb <- ROSE(
  adolescente ~ .,
  data = train_data,
  seed = 123
)$data

table(train_balanced_nb$adolescente)

```

```

##
##      No      Si
## 103155 102606

```

```

nb2 <- naiveBayes(
  adolescente ~ .,
  data = train_balanced_nb
)

```

```

nb_res2 <- evaluar_nb(
  nb2,
  test_data,

```

```

nombre_modelo = "NB2 - ROSE balanceado"
)

```

```

##
## =====
## Modelo: NB2 - ROSE balanceado
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 47992  443
##           Si 38471 1276
##
## Accuracy : 0.5587
## Precision: 0.0321
## Recall   : 0.7423
## F1-score : 0.0615
## AUC-ROC  : 0.6959

```

Al aplicar ROSE al conjunto de entrenamiento, el modelo Naive Bayes mejoró significativamente su capacidad para detectar casos positivos. El recall aumentó de 0 a 0.7423, confirmando que el balanceo de clases permite al modelo aprender patrones asociados a la maternidad adolescente. Aunque la precisión sigue siendo baja debido al gran número de falsos positivos, el F1-score mejora respecto al modelo sin balancear, indicando un mejor equilibrio entre sensibilidad y precisión.

Modelo 3 — ROSE + Laplace

```

nb3 <- naiveBayes(
  adolescente ~ .,
  data = train_balanced_nb,
  laplace = 1
)

nb_res3 <- evaluar_nb(
  nb3,
  test_data,
  nombre_modelo = "NB3 - ROSE + Laplace"
)

```

```

##
## =====
## Modelo: NB3 - ROSE + Laplace
## Threshold: 0.5
## =====
##           Reference
## Prediction    No    Si
##           No 48013  443
##           Si 38450 1276
##
## Accuracy : 0.5589
## Precision: 0.0321
## Recall   : 0.7423
## F1-score : 0.0616
## AUC-ROC  : 0.6961

```

El suavizado de Laplace permitió evitar probabilidades iguales a cero en categorías poco frecuentes, mejorando ligeramente la estabilidad del modelo Naive Bayes. Aunque las mejoras numéricas respecto al Modelo 2 son pequeñas, el Modelo 3 obtuvo el mayor F1-score y AUC-ROC entre los modelos Naive Bayes evaluados, por lo que puede considerarse el mejor modelo dentro de esta familia.

conclusiones

La aplicación de modelos de clasificación permitió evaluar distintos enfoques para predecir la probabilidad de maternidad adolescente utilizando variables sociodemográficas y territoriales derivadas de los registros de nacimientos. Debido al fuerte desbalance del dataset — aproximadamente 98% de casos “No” y 2% de casos “Si” — los modelos entrenados sin técnicas de balanceo mostraron un desempeño engañosamente alto en accuracy, pero fueron incapaces de detectar correctamente la clase minoritaria.

En la regresión logística, el Modelo 1 sin balancear obtuvo una accuracy cercana al 98%, pero un recall igual a 0, ya que clasificó prácticamente todos los registros como “No”. Esto confirmó que accuracy no es una métrica adecuada en problemas con clases altamente desbalanceadas. Al aplicar ROSE para balancear el conjunto de entrenamiento, los Modelos 2 y 3 lograron detectar la mayoría de los casos positivos. El Modelo 2, utilizando threshold 0.5, alcanzó un recall de 0.8168 y un F1-score de 0.0587, mientras que el Modelo 3, con threshold 0.3, incrementó el recall hasta 0.9552 a costa de una disminución en precisión y accuracy. Esto evidenció el trade-off entre sensibilidad y falsos positivos: reducir el threshold permite detectar más casos reales, pero también incrementa significativamente las alertas incorrectas.

Con el uso de ROSE, el Modelo 2 mejoró considerablemente su capacidad predictiva, alcanzando un recall de 0.7423 y un F1-score de 0.0615. Posteriormente, el Modelo 3 incorporó Laplace smoothing para evitar probabilidades nulas en categorías poco frecuentes. Aunque las mejoras fueron pequeñas, este modelo obtuvo el mejor desempeño dentro de la familia Naive Bayes, con un F1-score de 0.0616 y AUC-ROC de 0.6961, mostrando una ligera mejora en estabilidad y generalización.

Comparando ambas familias de modelos, la regresión logística con ROSE presentó el mayor recall global, especialmente al reducir el threshold, mientras que Naive Bayes logró un F1-score ligeramente superior con un comportamiento más estable. Sin embargo, todos los modelos mantuvieron precisiones bajas debido al gran número de falsos positivos generados al intentar detectar una clase tan minoritaria. Esto refleja la dificultad inherente del problema y la limitada separabilidad entre clases utilizando únicamente las variables disponibles.

En términos prácticos, los resultados muestran que el balanceo de clases es indispensable para modelar fenómenos raros como la maternidad adolescente. Los modelos balanceados fueron capaces de identificar patrones asociados a nivel educativo, grupo étnico, departamento y lugar de ocurrencia del nacimiento, variables que ya habían mostrado relevancia en el análisis exploratorio previo. Además, los odds ratios de la regresión logística confirmaron que niveles educativos más altos disminuyen significativamente la probabilidad de maternidad adolescente, mientras que ciertos departamentos presentan riesgos relativos mayores.